proglib.academy

Математика для Data Science

2. Линейная регрессия и МНК

Ксения Кондаурова

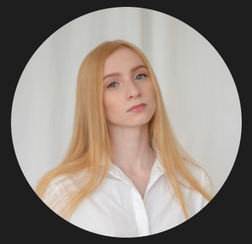

- выпускница механико-математического факультета МГУ
- преподаватель и автор курсов для бакалавриата Центрального Университета (Т-Банк)
- спикер и методист для магистратуры Edutoria (Сбербанк)
- участница конференций и научных форумов по теории вероятностей

План вебинара

Теория:

- линейная зависимость векторов, базис
- системы линейных уравнений и их матрицы, ранг
- модель машинного обучения, частный случай – линейная регрессия
- метод наименьших квадратов как способ нахождения оптимальных параметров

Практика в Python:

- реализация МНК «вручную» и сравнение с scikit-learn

Литература

Математика:

- Винберг Э.Б. «Курс алгебры»
- Кострикин А.И. «Введение в алгебру. Части I-III»

Машинное обучение:

- Bishop C. M. «Pattern recognition and machine learning»

Python:

- официальная документация NumPy
- официальная документация scikit-learn

Понятие вектора (алгебраическое)

Вектором в n-мерном пространстве действительных чисел $\mathbb{R}^n$ называется упорядоченный набор чисел $\boldsymbol{a} = \left(a^1, a^2, \ldots, a^n\right)$.

Операция сложения векторов:

$$\boldsymbol{a} = \left(a^1, a^2, \ldots, a^n\right)$$
$$\boldsymbol{b} = \left(b^1, b^2, \ldots b^n\right)$$
$$\boldsymbol{a} + \boldsymbol{b} = (a^1 + b^1, a^2 + b^2, \ldots, a^n + b^n)$$

Операция умножения вектора на скаляр:

$$\lambda \boldsymbol{a} = \left(\lambda a^1, \lambda a^2, \ldots, \lambda a^n\right)$$

Линейное пространство

Линейным (векторным) пространством над полем $\mathbb{R}$ называется множество V с заданными операциями сложения и умножения такими, что выполнены следующие свойства:

1) для любых $\boldsymbol{a},\boldsymbol{b}\in V$ $\quad \boldsymbol{a}+\boldsymbol{b}=\boldsymbol{b}+\boldsymbol{a}$;
2) для любых $\boldsymbol{a},\boldsymbol{b},\boldsymbol{c}\in V$ $\quad (\boldsymbol{a}+\boldsymbol{b})+\boldsymbol{c}=\boldsymbol{a}+(\boldsymbol{b}+\boldsymbol{c})$;
3) существует элемент $\boldsymbol{0}\in V$: $\quad \boldsymbol{a}+\boldsymbol{0}=\boldsymbol{a}$;
4) для любого элемента $\boldsymbol{a}\in V$ существует элемент $-\boldsymbol{a}\in V$: $\quad \boldsymbol{a}+(-\boldsymbol{a})=0$;
5) существует элемент $1\in\mathbb{R}$: $\quad \boldsymbol{a}\cdot 1=\boldsymbol{a}$;
6) для любых $\lambda,\mu\in\mathbb{R}$, $\boldsymbol{a}\in V$ $\quad (\lambda\mu)\boldsymbol{a}=\lambda(\mu\boldsymbol{a})$;
7) для любых $\lambda,\mu\in\mathbb{R}$, $\boldsymbol{a}\in V$ $\quad (\lambda+\mu)\boldsymbol{a}=\lambda\boldsymbol{a}+\mu\boldsymbol{a}$;
8) для любых $\lambda\in\mathbb{R}$, $\boldsymbol{a},\boldsymbol{b}\in V$ $\quad \lambda(\boldsymbol{a}+\boldsymbol{b})=\lambda\boldsymbol{a}+\lambda\boldsymbol{b}$.

Множество строк длины n являетсям линейным пространством над полем $\mathbb{R}$ относительно операций, определённых формулами:

$$\left(a^1,a^2,\ldots,a^n\right)+\left(b^1,b^2,\ldots b^n\right)=(a^1+b^1,a^2+b^2,\ldots,a^n+b^n),$$
$$\lambda\left(a^1,a^2,\ldots,a^n\right)=\left(\lambda a^1,\lambda a^2,\ldots,\lambda a^n\right).$$

Линейная комбинация

Линейной комбинацией векторов $\boldsymbol{a_1}, \boldsymbol{a_2}, \ldots \boldsymbol{a_n} \in V$ называется выражение вида:

$$\lambda_1 \boldsymbol{a_1} + \lambda_2 \boldsymbol{a_2} + \ldots + \lambda_n \boldsymbol{a_n},$$

где $\lambda_1, \lambda_2, \ldots \lambda_n \in \mathbb{R}$.

Если $\lambda_1 = \lambda_2 = \ldots = \lambda_n = 0$, то комбинация называется **тривиальной**.

Пример для $\mathbb{R}^2$:

$$\mathbf{a}_1 = \begin{pmatrix} 1 \\ 2 \end{pmatrix}, \quad \mathbf{a}_2 = \begin{pmatrix} 3 \\ -1 \end{pmatrix}, \quad \lambda_1 = 2, \quad \lambda_2 = -1$$

$$\mathbf{u} = \lambda_1 \mathbf{a}_1 + \lambda_2 \mathbf{a}_2 = 2 \begin{pmatrix} 1 \\ 2 \end{pmatrix} + (-1) \begin{pmatrix} 3 \\ -1 \end{pmatrix} = \begin{pmatrix} -1 \\ 5 \end{pmatrix}$$

$$\begin{pmatrix} 2 \\ 4 \end{pmatrix} + \begin{pmatrix} -3 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 5 \end{pmatrix}$$

Пример

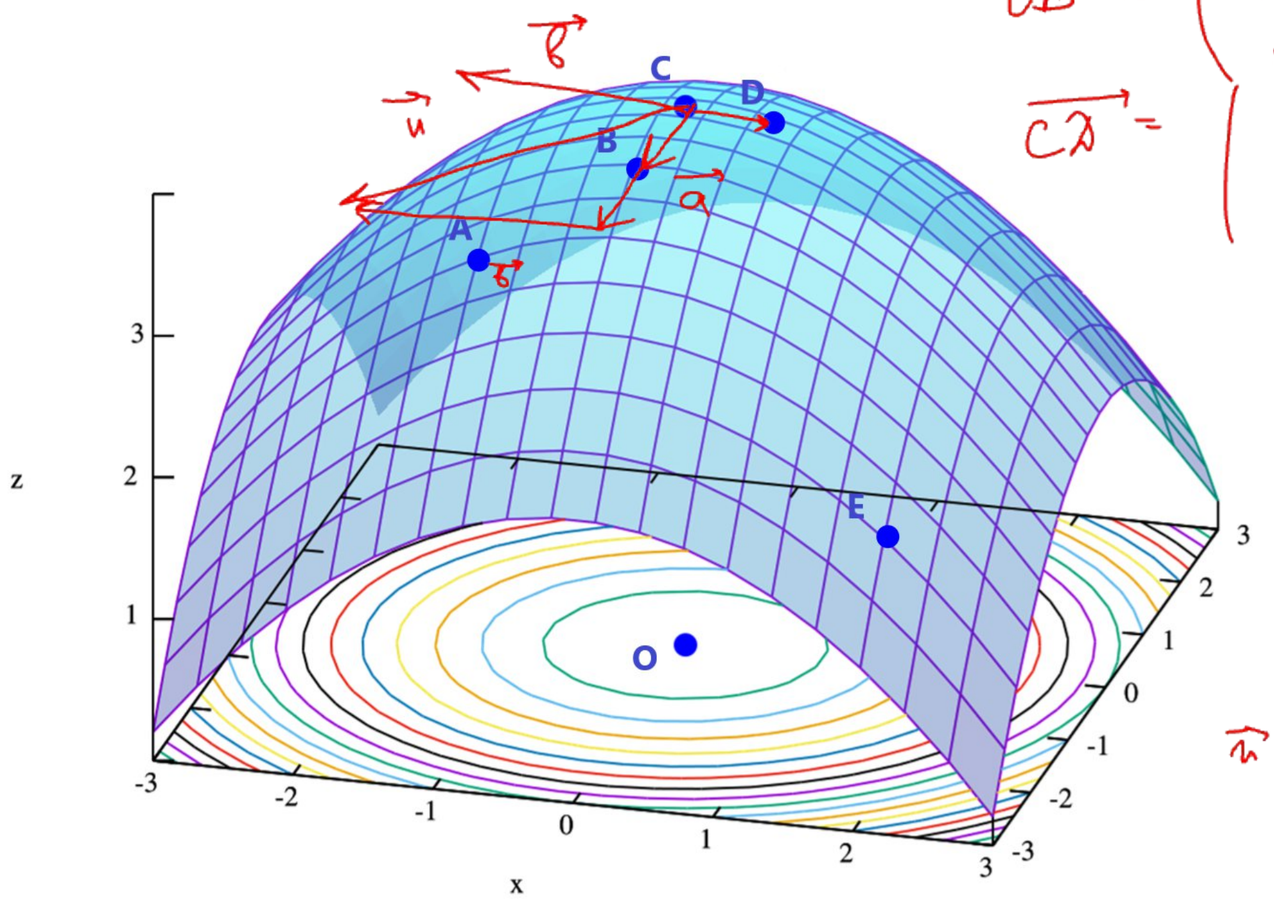

$$\overrightarrow{CB} = \begin{pmatrix} 0 \\ -1 \\ 0 \end{pmatrix}$$

$$\overrightarrow{CD} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$\lambda_1 = 2$$

$$\lambda_2 = -3$$

$$\vec{a} = 2\overrightarrow{CB}$$

$$\vec{b} = -3\overrightarrow{CD}$$

$$\vec{u} = \vec{a} + \vec{b} = \begin{pmatrix} 0 \\ -2 \\ 0 \end{pmatrix} + \begin{pmatrix} -3 \\ 0 \\ 0 \end{pmatrix} = \begin{pmatrix} -3 \\ -2 \\ 0 \end{pmatrix}$$

Линейная зависимость векторов

$c = \begin{pmatrix} 3 \\ 1 \end{pmatrix}$ $d = \begin{pmatrix} 7 \\ 10 \end{pmatrix}$

Векторы $\boldsymbol{a_1}, \boldsymbol{a_2}, \ldots \boldsymbol{a_n} \in V$ называется **линейно зависимыми**, если существует нетривиальная линейная комбинация, равная нулю:

$$\lambda_1 \boldsymbol{a_1} + \lambda_2 \boldsymbol{a_2} + \ldots + \lambda_n \boldsymbol{a_n} = 0,$$

где не все $\lambda_1, \lambda_2, \ldots \lambda_n$ равны 0.

$a = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$ $b = \begin{pmatrix} -4 \\ 2 \end{pmatrix}$

$2a + 1 \cdot b = \begin{pmatrix} 4 \\ -2 \end{pmatrix} + \begin{pmatrix} -4 \\ 2 \end{pmatrix} = \begin{pmatrix} 0 \\ 0 \end{pmatrix}$

$\lambda_1 \neq 0$ $\lambda_2 \neq 0$

В противном случае векторы называются **линейно независимыми**.

Линейная зависимость показывает, насколько векторы «дублируют» друг друга по смыслу. Если один вектор можно получить из других, он не добавляет новой информации. Например,

$$\boldsymbol{a_2} = 2\boldsymbol{a_1}$$

— значит, второй вектор не даёт ничего нового, они указывают одно и то же направление.

Пример

На плоскости: векторы линейно зависимы $\Longleftrightarrow$ векторы коллинеарны.

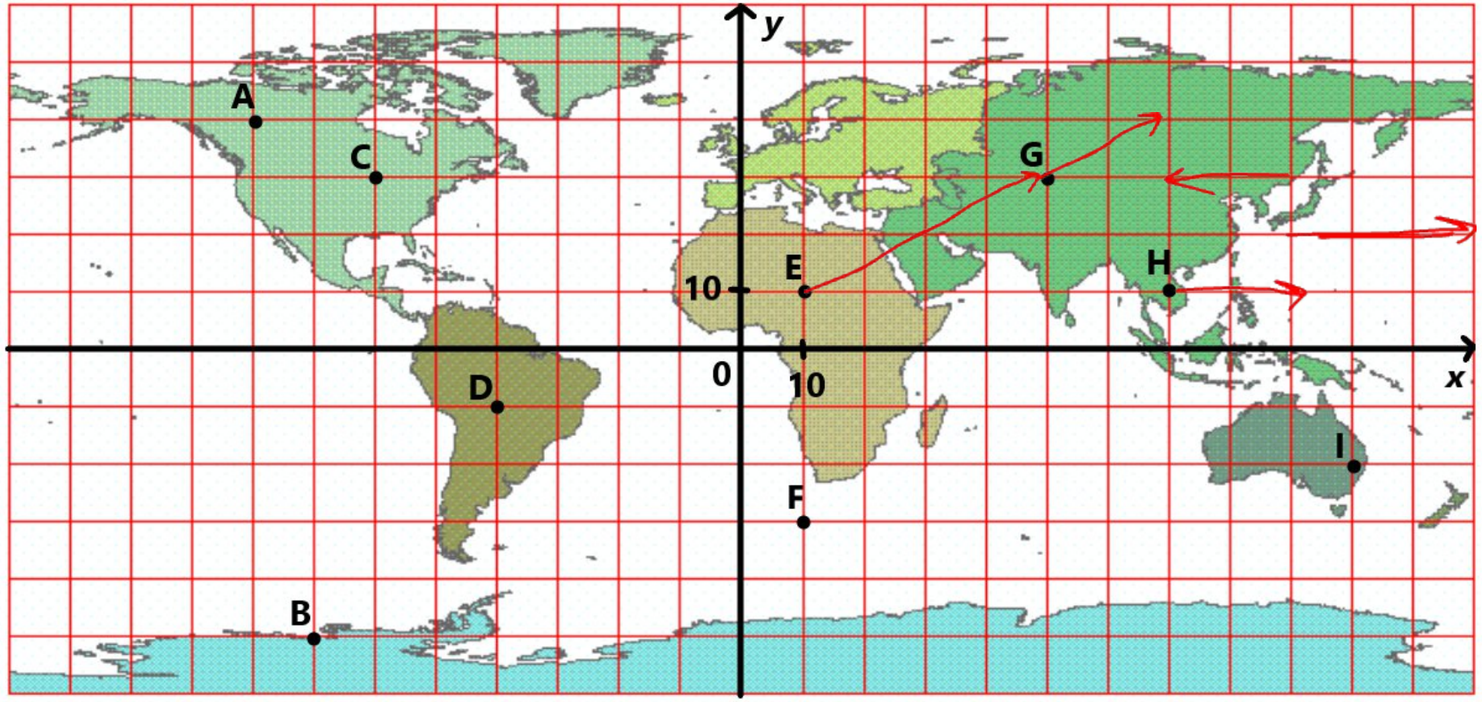

Пример

В пространстве:

- два вектора линейно зависимы $\Longleftrightarrow$ два вектора коллинеарны;
- три вектора линейно зависимы три вектора лежат в одной плоскости.

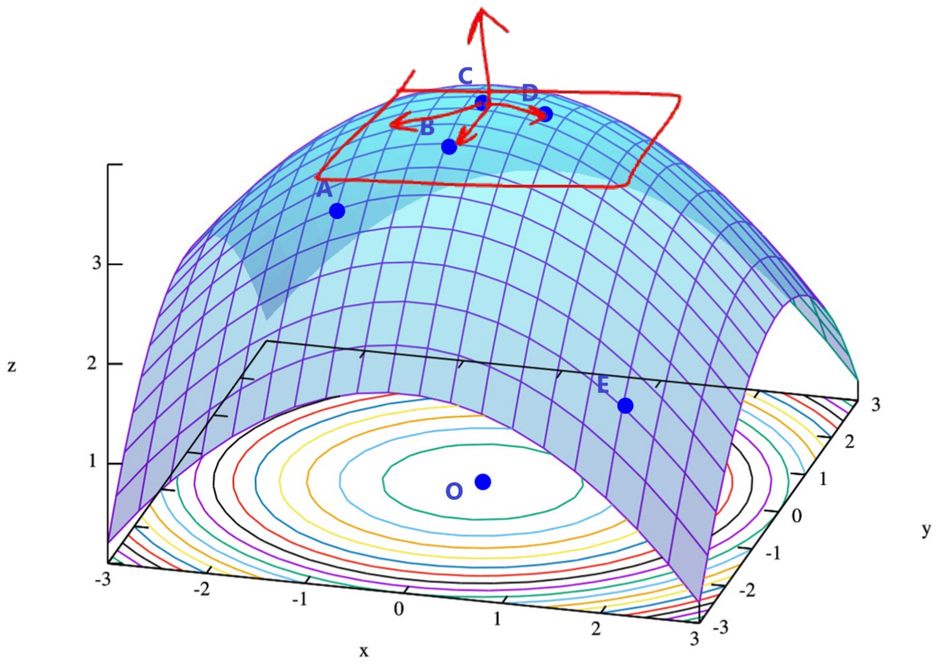

proglib.academy

Пример

Маркетинговая аналитика

клиент = (возраст, доход, частота покупок, отклик на рекламу)

➡ A = (25; 50; 8; 0.65)

➡ B = (30; 60; 4; 0.55)

➡ C = (40; 80; 10; 0.35)

Мультиколлинеарность — это явление в статистике и машинном обучении, когда два или более признака (features) в модели сильно связаны между собой, то есть один признак можно почти предсказать через другие.

Базис

Система векторов $\{\boldsymbol{e_1}, \boldsymbol{e_2}, \ldots \boldsymbol{e_n}\} \subset V$ называется **базисом** векторного пространства V, если каждый вектор $\boldsymbol{a} \in V$ единственным образом линейно выражается через $\boldsymbol{e_1}, \boldsymbol{e_2}, \ldots \boldsymbol{e_n}$:

$$\boldsymbol{a} = a^1 \boldsymbol{e_1} + a^2 \boldsymbol{e_2} + \ldots + a^n \boldsymbol{e_n}.$$

Коэффициенты $\left(a^1, a^2, \ldots, a^n\right)$ называются **координатами** вектора $\boldsymbol{a}$ в базисе $\{\boldsymbol{e_1}, \boldsymbol{e_2}, \ldots \boldsymbol{e_n}\}$.

Координаты вектора зависят от выбранного базиса.

Система линейно независимых векторов называется **максимальной**, если при добавлении в эту систему любого вектора из пространства V получается линейно зависимая система.

Базис – максимальная линейно независимая система векторов.

Количество векторов в базисе = размерность пространства.

Пример

$e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \quad e_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$a = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \quad a = 2e_1 + 3e_2$

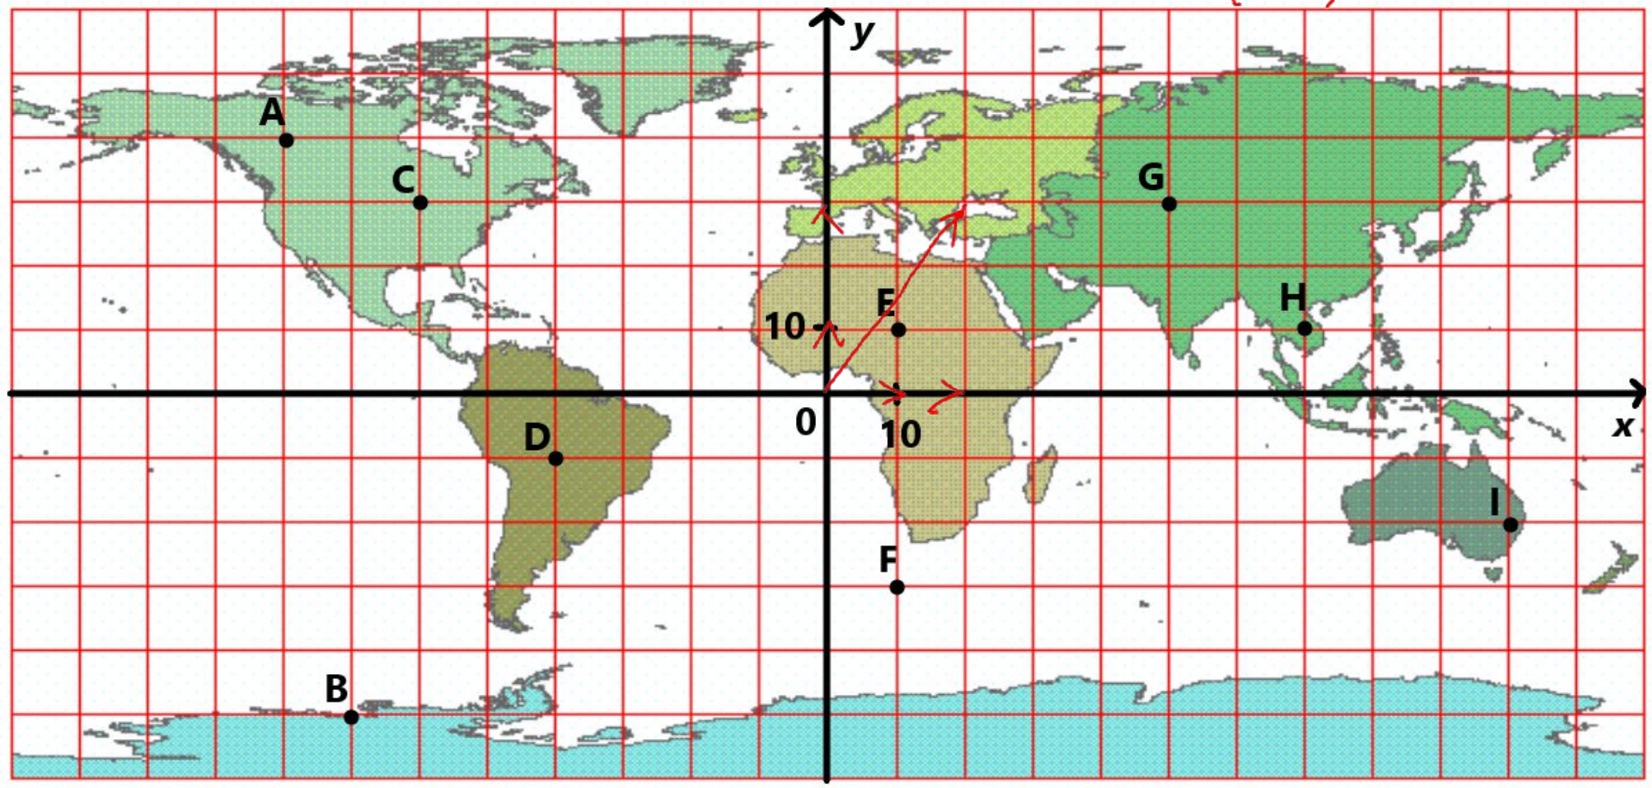

proglib.academy

Пример

$$e_1 = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \quad e_2 = \begin{pmatrix} 0 \\ 1 \\ 0 \end{pmatrix} \quad e_3 = \begin{pmatrix} 0 \\ 0 \\ 1 \end{pmatrix}$$

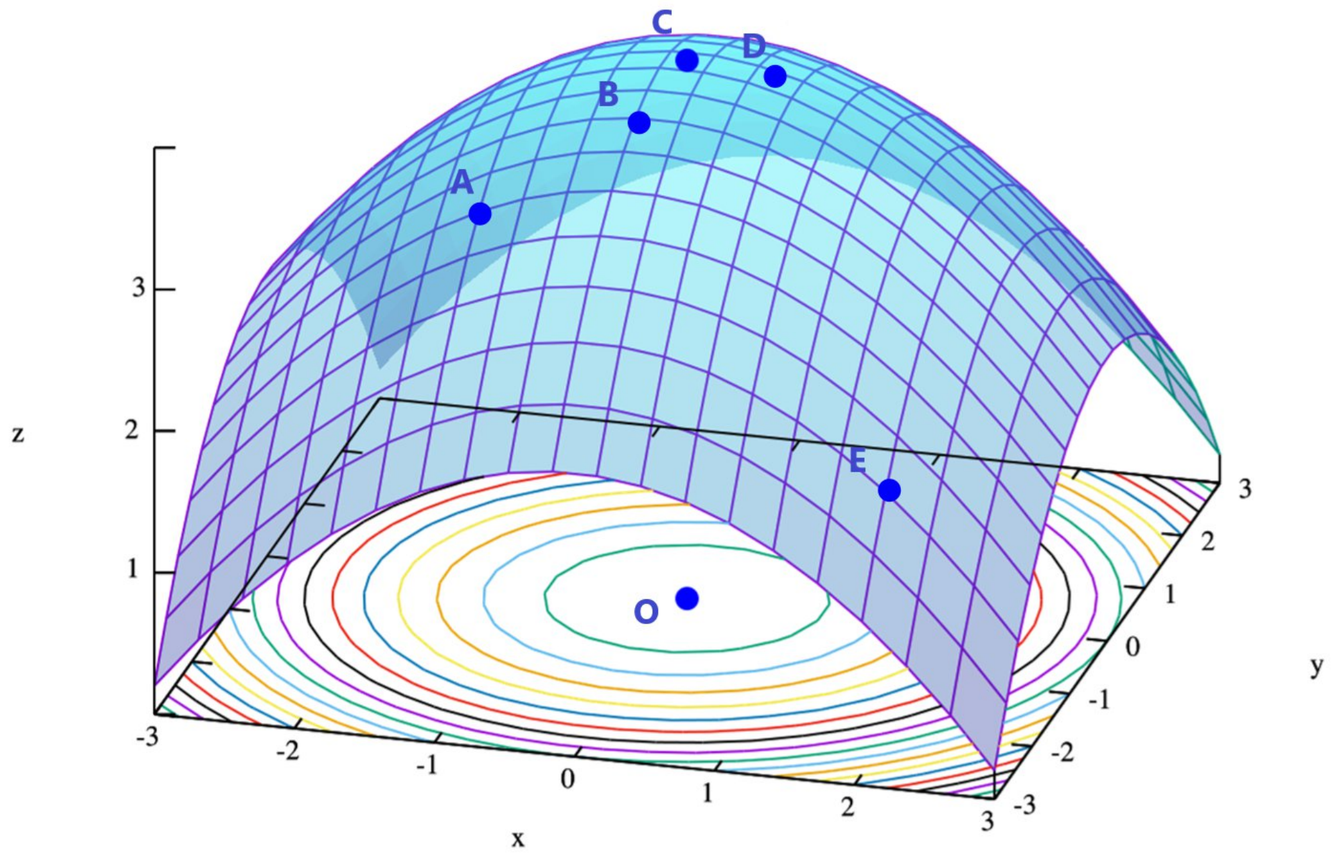

Ранг системы векторов

Линейной оболочкой системы векторов $a_1, a_2, \ldots a_n, \ldots \in V$ называется множество векторов пространства V, представимых в виде линейной комбинации векторов этой системы.
Обозначение: $< a_1, a_2, \ldots a_n, \ldots >$.

$\lambda_1 a_1 + \lambda_3 a_3$

Рангом системы векторов называется размерность её линейной оболочки.

Пример:

$$\mathbf{a}_1 = \begin{pmatrix} 1 \\ 2 \\ 3 \end{pmatrix}, \quad \mathbf{a}_2 = \begin{pmatrix} 2 \\ 4 \\ 6 \end{pmatrix}, \quad \mathbf{a}_3 = \begin{pmatrix} 1 \\ 0 \\ 1 \end{pmatrix}$$

Ранг системы векторов равен 2.

$a_2 = 2a_1$

proglib.academy

Система линейных уравнений

Система m линейных уравнений с n неизвестными:

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \cdots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \cdots + a_{2n}x_n = b_2 \\ \quad\vdots \\ a_{m1}x_1 + a_{m2}x_2 + \cdots + a_{mn}x_n = b_m \end{cases}$$

$$\begin{cases} 3x_1 + 2x_2 = 1 \\ -x_1 + x_3 = 2 \end{cases}$$

$$A = \begin{pmatrix} 3 & 2 & 0 \\ -1 & 0 & 1 \end{pmatrix}$$

$$x = \begin{pmatrix} x_1 \\ x_2 \\ x_3 \end{pmatrix}$$

$$b = \begin{pmatrix} 1 \\ 2 \end{pmatrix}$$

$$A|b = \left(\begin{array}{ccc|c} 3 & 2 & 0 & 1 \\ -1 & 0 & 1 & 2 \end{array}\right)$$

Матричная форма: $A\mathbf{x} = \mathbf{b}$

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}, \quad \mathbf{x} = \begin{pmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{pmatrix}, \quad \mathbf{b} = \begin{pmatrix} b_1 \\ b_2 \\ \vdots \\ b_m \end{pmatrix}$$

Система линейных уравнений

Матрица коэффициентов:

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

Расширенная матрица системы:

$$\left(\begin{array}{cccc|c} a_{11} & a_{12} & \dots & a_{1n} & b_1 \\ a_{21} & a_{22} & \dots & a_{2n} & b_2 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} & b_m \end{array}\right)$$

Удобнее работать не с самими системами линейных уравнений, а с их (расширенными) матрицами.

Решение системы линейных уравнений

Система уравнений называется **совместной**, если она имеет хотя бы одно решение, и **несовместной** в противном случае.

Совместная система может иметь одно или более решений. Решить систему уравнений — это значит найти все ее решения.

Решение системы линейных уравнений

Существует общий метод решения систем линейных уравнений, называемый **методом Гаусса**. Его идея состоит в приведении любой системы линейных уравнений с помощью элементарных преобразований к эквивалентной системе некоторого простого вида, все решения которой легко найти.

Элементарные преобразования строк:
1) прибавление к одной строке другой, умноженной на число;
2) перестановка двух строк ;
3) умножение одной строки на число, отличное от нуля.

Решение системы линейных уравнений

С помощью элементарных преобразований строк любую матрицу можно привести к **ступенчатому виду**:

$$\begin{pmatrix} a_{1j_1} & \cdots & \cdots & \cdots & \cdots \\ & a_{2j_2} & \cdots & \cdots & \cdots \\ & & \cdots & \cdots & \cdots \\ & & & \cdots & \cdots \\ 0 & & & & a_{rj_r} \cdots \end{pmatrix}$$

$$\begin{pmatrix} 1 & 2 & 3 & 4 & 5 \\ 0 & 0 & 1 & 2 & 3 \\ 0 & 0 & 0 & 1 & 2 \\ 0 & 0 & 0 & 0 & 1 \end{pmatrix}$$

Задача

Решить систему линейных уравнений методом Гаусса.

$$\begin{cases} x + y + z = 6 \\ 2x - y + 3z = 14 \\ x + 2y - z = 2 \end{cases}$$

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 2 & -1 & 3 & 14 \\ 1 & 2 & -1 & 2 \end{array}\right) \cdot (-2) \quad \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ \boxed{0} & -3 & 1 & 2 \\ \boxed{0} & 1 & -2 & -4 \end{array}\right) \cdot 3 \quad \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & -2 & -4 \\ 0 & 0 & -5 & -10 \end{array}\right)$$

Реш.: $\begin{pmatrix} 4 \\ 0 \\ 2 \end{pmatrix}$

$x = 4 \iff x + 0 + 2 = 6 \iff x + y + z = 6$

$y = 0 \iff y - 4 = -4 \iff y - 2z = -4$

$z = 2 \iff -5z = -10$

Геометрическая интерпретация

Каждое линейное уравнение системы задаёт гиперплоскость в $\mathbb{R}^n$. Значит, система линейных уравнений задаёт пересечение m плоскостей в $\mathbb{R}^n$.

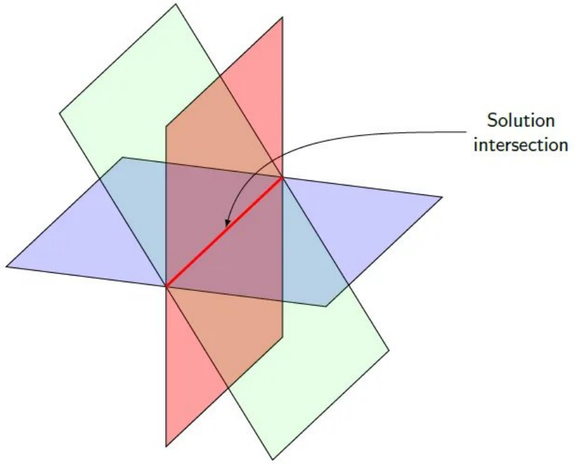

Ранг матрицы

$$A = \begin{pmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{pmatrix}$$

$d_1 = d_2$

В любой прямоугольной матрице размерность линейной оболочки строк *равна* размерности линейной оболочки столбцов. Это число называется **рангом матрицы**.

Ранг матрицы не меняется при элементарных преобразованиях строк и равен числу ненулевых строк ступенчатой матрицы, к которой она приводится методом Гаусса.

Задача

Найти ранг матрицы.

$$A = \begin{pmatrix} 1 & 2 & 3 & 4 \\ 2 & 4 & 6 & 8 \\ 1 & 1 & 1 & 1 \end{pmatrix} \begin{matrix} \mid \cdot (-2) \\ \\ \end{matrix} \Big) +$$

$$\begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad \begin{pmatrix} 1 & 1 & 1 & 1 \\ 0 & 1 & 2 & 3 \\ 0 & 0 & 0 & 0 \end{pmatrix} \quad \text{rank} = 2$$

Связь ранга матрицы и определителя

Ранг матрицы — это максимальное число линейно независимых строк (или столбцов).

- Ранг матрицы равен числу её строк $\Longleftrightarrow$ строки линейно независимы $\Longleftrightarrow$ определитель матрицы не равен нулю $\Longleftrightarrow$ матрица **невырожденная**.

$$A = \begin{pmatrix} 1 & 2 & 1 \\ 0 & 1 & 3 \\ 0 & 0 & 2 \end{pmatrix}, \quad \operatorname{rank}(A) = 3$$

$$\det A = 2 + 0 + 0 - 0 - 0 - 0 = 2 \neq 0$$

Связь ранга матрицы и определителя

- Ранг матрицы меньше числа её строк $\Longleftrightarrow$ строки линейно зависимы $\Longleftrightarrow$ определитель матрицы равен нулю $\Longleftrightarrow$ матрица **вырожденная**.

$$B = \begin{pmatrix} 1 & 2 & 3 \\ 0 & 1 & 2 \\ 0 & 0 & 0 \end{pmatrix}, \quad \operatorname{rank}(B) = 2$$

$\det B = 0$

Теорема Кронекера-Капелли

Система линейных уравнений имеет хотя бы одно решение тогда и только, когда ранг её матрицы совпадает с рангом расширенной матрицы:

$$\mathrm{rank}(A) = \mathrm{rank}(A|B)$$

Следствие:

1. Если $\mathrm{rank}(A) = \mathrm{rank}(A|B) = n$, где n – число неизвестных, то система имеет единственное решение.
2. Если $\mathrm{rank}(A) = \mathrm{rank}(A|B) < n$, где n – число неизвестных, то система имеет бесконечно много решений.

Задача

Определи число решений системы линейных уравнений.

$$\begin{cases} x + y = 2 \\ 2x + 2y = 5 \end{cases}$$

$$A = \begin{pmatrix} 1 & 1 \\ 2 & 2 \end{pmatrix} \overset{|\cdot(-2)}{\sim} \begin{pmatrix} 1 & 1 \\ 0 & 0 \end{pmatrix} \qquad \text{rank } A = 1$$

$$A|B = \left(\begin{array}{cc|c} 1 & 1 & 2 \\ 2 & 2 & 5 \end{array}\right) \overset{|\cdot(-2)}{\sim} \left(\begin{array}{cc|c} 1 & 1 & 2 \\ 0 & 0 & 1 \end{array}\right) \qquad \text{rank } A|B = 2$$

$$\text{rank } A \neq \text{rank } A|B$$

$\Rightarrow$ решений нет

$$0 \cdot x + 0 \cdot y = 1$$

$$0 \neq 1$$

Задача

Определи число решений системы линейных уравнений.

$$\begin{cases} x + y + z = 6 \\ 2x - y + z = 3 \\ x + 2y - z = 3 \end{cases}$$

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 2 & -1 & 1 & 3 \\ 1 & 2 & -1 & 3 \end{array}\right) \begin{array}{l} \\ |\cdot(-2) \\ \\ \end{array} \quad \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & -3 & -1 & -9 \\ 0 & 1 & -2 & -3 \end{array}\right) \begin{array}{l} \\ \\ |\cdot 3 \end{array} \quad \left(\begin{array}{ccc|c} 1 & 1 & 1 & 6 \\ 0 & 1 & 2 & -3 \\ 0 & 0 & -7 & -18 \end{array}\right)$$

$$\underbrace{\underbrace{\begin{matrix} 1 & 1 & 1 \\ 0 & 1 & 2 \\ 0 & 0 & -7 \end{matrix}}_{3} \left|\begin{matrix} 6 \\ -3 \\ -18 \end{matrix}\right.}_{3}$$

$$\text{rank } A = \text{rank } A|B = 3$$

Задача

Определи число решений системы линейных уравнений.

$$\begin{cases} x + y + z = 2 \\ 2x + 2y + 2z = 4 \end{cases}$$

$$\left(\begin{array}{ccc|c} 1 & 1 & 1 & 2 \\ 2 & 2 & 2 & 4 \end{array}\right) \quad \left(\begin{array}{ccc|c} 1 & 1 & 1 & 2 \\ 0 & 0 & 0 & 0 \end{array}\right)$$

$$\text{rank } A = \text{rank } A|B = 1 < 3$$

$$x = 2 - s - t$$
$$y = s, \quad s \in \mathbb{R}$$
$$z = t, \quad t \in \mathbb{R}$$

$$\begin{pmatrix} x \\ y \\ z \end{pmatrix} = \begin{pmatrix} 2 - s - t \\ s \\ t \end{pmatrix}$$

proglib.academy

Первое упоминание регрессии

Впервые регрессия упоминается в работе Фрэнсиса Гальтона ”Регрессия к середине в наследственности роста” (1885).

x — рост родителей, y — рост детей, $\bar{x}$— средний рост родителей, $\bar{y}$— средний рост детей
Установлена зависимость: $y-\bar{y} \approx \frac{2}{3}(x-\bar{x})$, т.е. регрессия к середине.

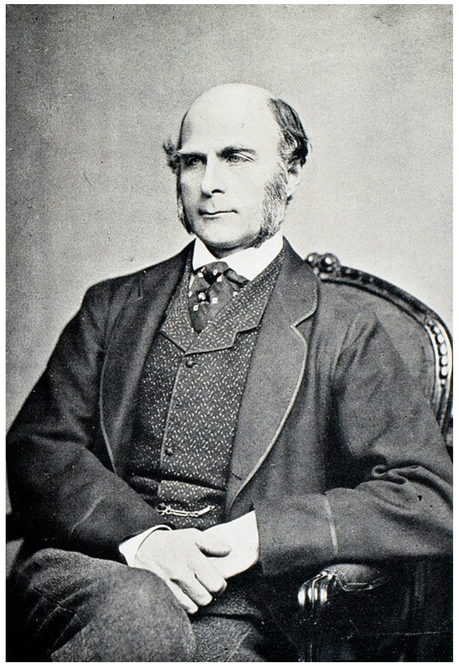

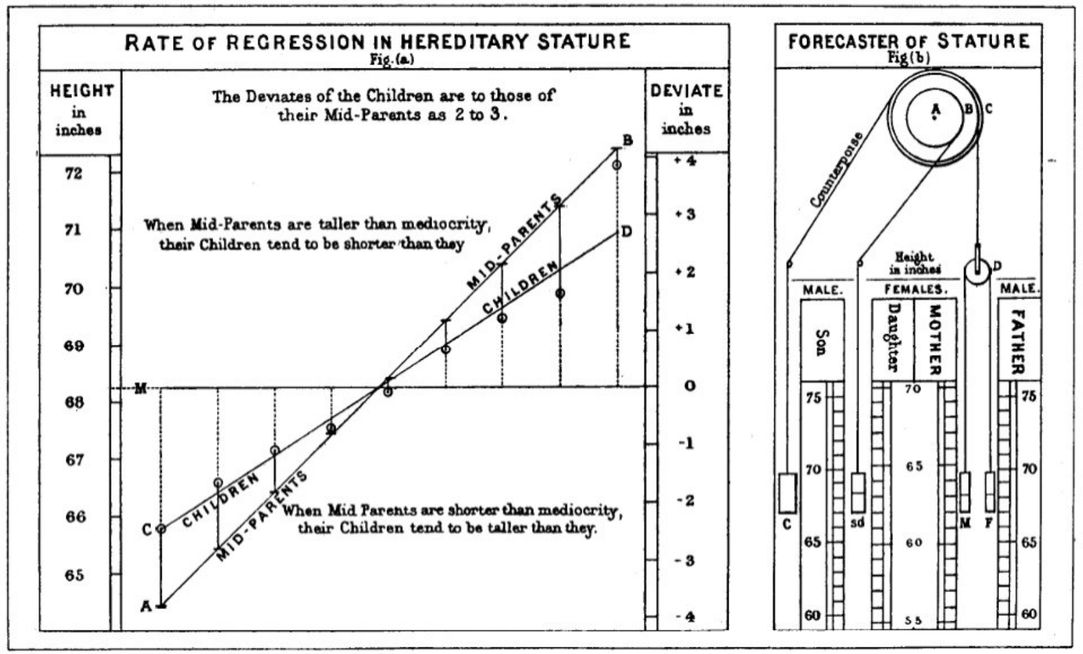

Задача регрессии

x_1 — рост матери (см)
x_2 — рост отца (см)
y — рост ребёнка (см)

Задача регрессии: по известному росту родителей предсказать рост ребёнка.

Строится **линейная модель**, которая предсказывает рост ребёнка на основе роста родителей:

$$y = w_1 \cdot x_1 + w_2 \cdot x_2 + w_0 ,$$

где w_1, w_2 — веса, показывающие влияние роста матери и отца на рост ребёнка, w_0 — сдвиг.

Интерпретация:

- Если $w_1 > w_2$, значит рост матери сильнее влияет на рост ребёнка.
- Если $w_1 < w_2$, значит рост отца сильнее влияет на рост ребёнка.

Обучение с учителем для регрессии

Задача: научиться предсказывать рост ребёнка на основе роста матери и отца.

Проблема: заранее неизвестно, как сильно каждый признак (рост матери, рост отца) влияет на результат. То есть неизвестны сдвиг и веса, которые нужно присвоить каждому признаку.

Решение: использовать *обучающие данные* — примеры, где известны входные признаки и правильный результат: рост матери, рост отца → рост ребёнка. Используя эти данные, компьютер подбирает оптимальные коэффициенты (веса и сдвиг), чтобы предсказания были как можно ближе к реальным значениям.

Результат: после *обучения* получается модель, которая умеет предсказывать рост ребёнка для новых родителей, даже если их данные не были в обучающей выборке.

proglib.academy

Задача

Вычислить коэффициенты регрессии по обучающим данным из таблицы.

Рост матери x_1	Рост отца x_2	Рост ребёнка y
160	170	172
165	175	177
170	170	177

$$y = w_1 x_1 + w_2 x_2 + w_0$$

$$\begin{cases} 160 w_1 + 170 w_2 + w_0 = 172 \\ 165 w_1 + 175 w_2 + w_0 = 177 \\ 170 w_1 + 170 w_2 + w_0 = 177 \end{cases}$$

$$\left(\begin{array}{ccc|c} 160 & 170 & 1 & 172 \\ 165 & 175 & 1 & 177 \\ 170 & 170 & 1 & 177 \end{array}\right)$$

proglib.academy

Визуализация точного решения

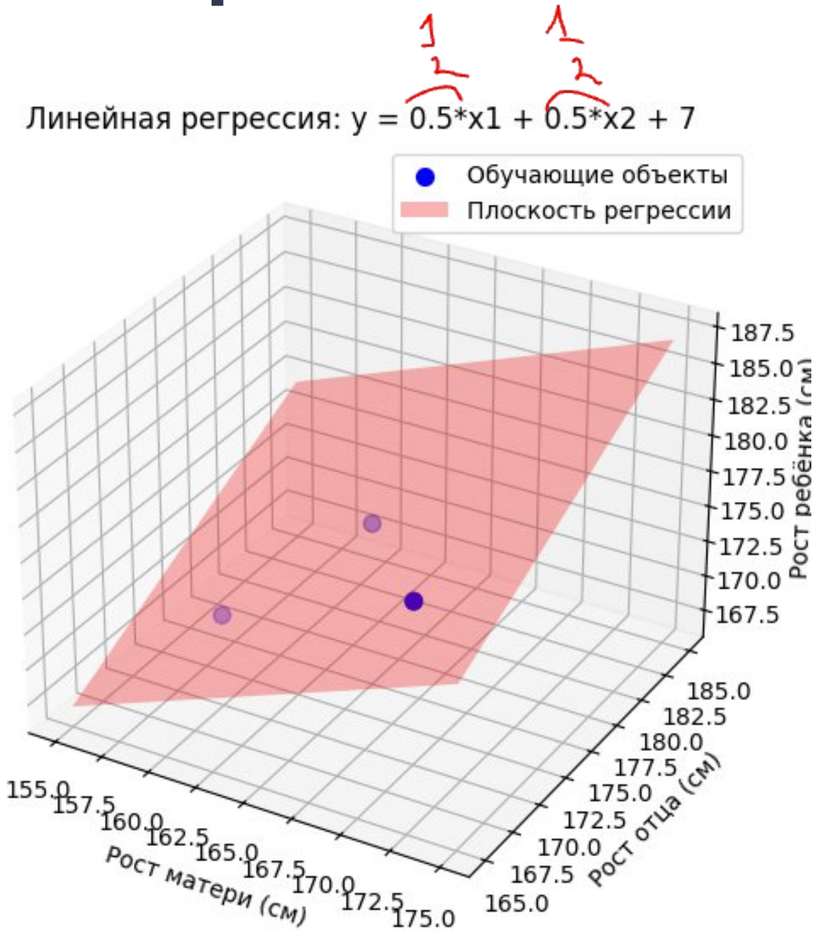

$$y = w_1 x_1 + w_0 + \varepsilon$$

Но в реальности приходится строить приближённые предсказания!

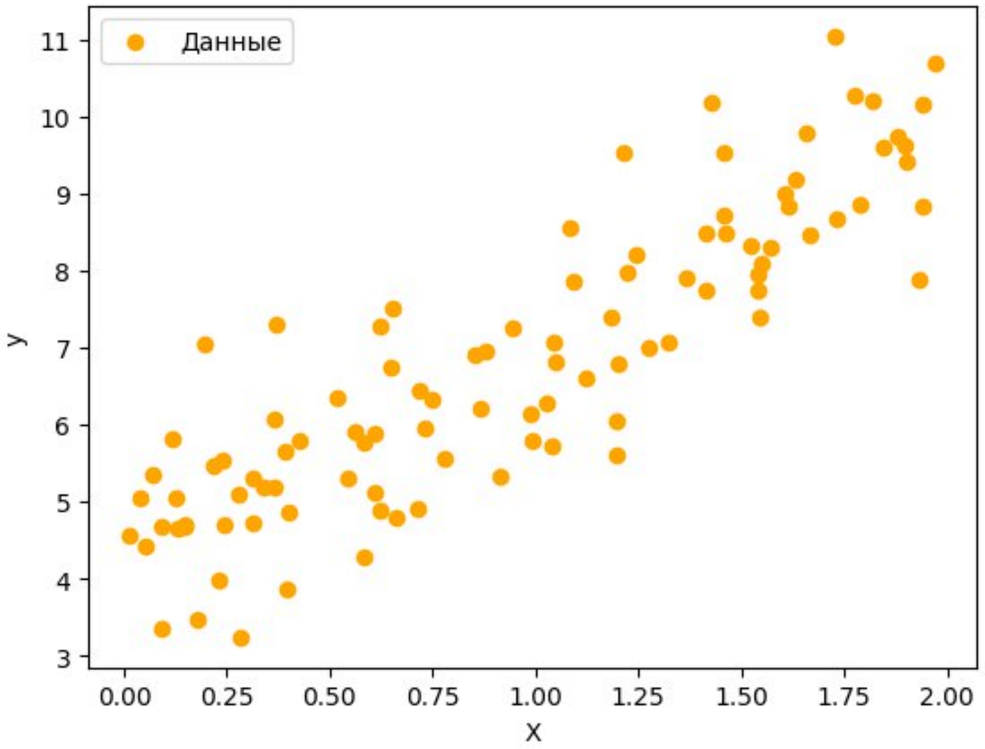

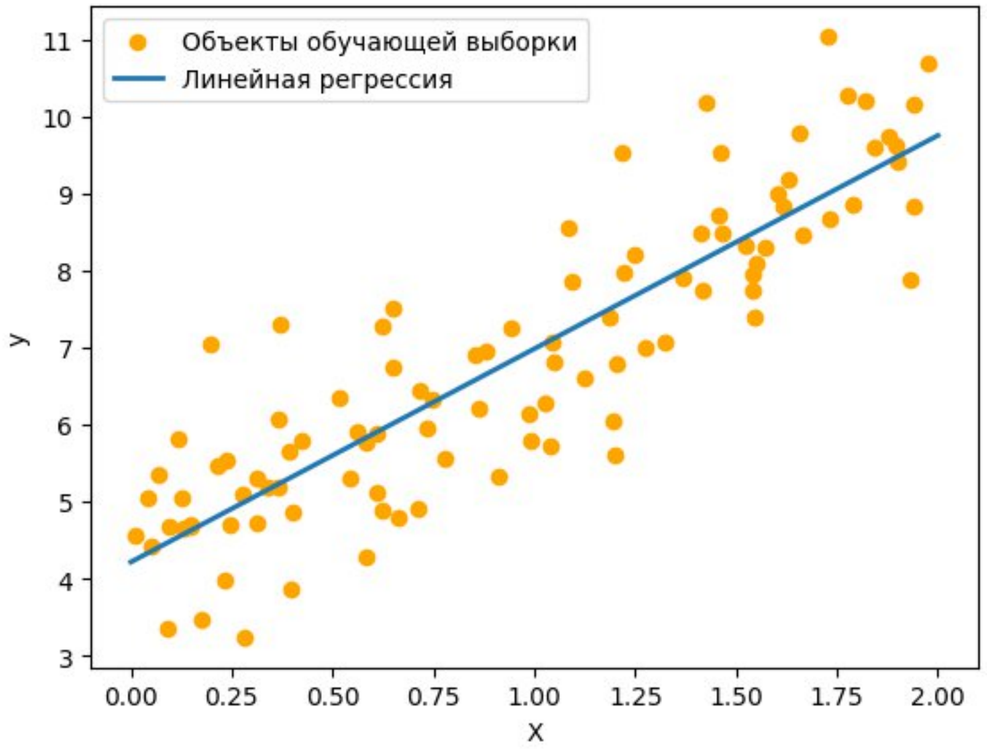

Модель машинного обучения

Пусть $\mathscr{X}$ – множество объектов, $\mathscr{Y}$ – множество меток.

Функция зависимости ответов от объектов $\rho : \mathscr{X} \to \mathscr{Y}$ называется **целевой функцией** *(target function)*.

В зависимости от задачи объекты могут иметь одномерное или многомерное описание. В одномерном случае каждый объект $X \in \mathscr{X}$ представляет собой число, в многомерном – вектор заданной размерности D. Во втором случае говорят, что **объект описывается D признаками**.

Модель машинного обучения

Предполагается, что функция $\rho : \mathscr{X} \to \mathscr{Y}$ существует, но не известна, а значения целевой функции $y_i = \rho(X_i)$ заданы только на конечном числе объектов $(X_1,...X_m)$, $X_i \in \mathscr{X}$.

Совокупность пар $M = \{(X_i, y_i) \mid i = 1,...m\}$ называется **обучающей выборкой** (training sample, dataset).

$X_i = (x_{i1}, x_{i2}, ..., x_{iD})$ – вектор признаков i -ого объекта обучающей выборке *(features)*

Матрица признаков X :

$$\mathbf{X} = \begin{pmatrix} x_{11} & x_{12} & \dots & x_{1D} \\ x_{21} & x_{22} & \dots & x_{2D} \\ \vdots & \vdots & \ddots & \vdots \\ x_{m1} & x_{m2} & \dots & x_{mD} \end{pmatrix}$$

Модель машинного обучения

Задача обучения с учителем заключается в том, чтобы по выборке M восстановить зависимость ρ.

То есть нужно построить **решающую функцию** (*decision function*) $a : \mathscr{X} \to \mathscr{Y}$, которая бы приближала целевую функцию ρ, причём не только на объектах обучающей выборки, но и на всём множестве $\mathscr{X}$.

Решающая функция должна допускать эффективную компьютерную реализацию,
по этой причине её принято называть **алгоритмом**.

Модель линейной регрессии

Линейная регрессия — это частный случай решающей функции a, при котором зависимость между признаками и откликом считается линейной:

$$a(X,w) = w_1 \ x_1 \ + w_2 \ x_2 \ + \ldots + w_D \ x_D \ + w_0 \ .$$

$X = (x_1, x_2, \ldots, x_D)$– вектор признаков *(features)*
$w = (w_1, w_2, \ldots, w_D)$ — вектор неизвестных параметров, весов *(weights)*
w_0 — сдвиг *(bias)*

Для любого объекта $X = (x_1, x_2, \ldots, x_D)$ можно вычислить предсказание модели $\hat{y}$:

$$\hat{y} = w_1 \ x_1 \ + w_2 \ x_2 \ + \ldots + w_D \ x_D \ + w_0 \ .$$

В векторной форме: $\hat{y} = (x,w) + w_0$.
В матричной форме: $\hat{y} = X^{\mathrm{T}} w + w_0$.

Обучение алгоритма

Алгоритм: $a(X,w) = w_1 \ x_1 \ + w_2 \ x_2 \ + \ldots + w_D \ x_D \ + w_0$.
Предсказание на объекте: $\hat{y} = w_1 \ x_1 \ + w_2 \ x_2 \ + \ldots + w_D \ x_D \ + w_0$.

По сути, $\hat{y}$ – это некоторое «приближение» целевой переменной y. Качество этого «приближения» зависит от точности подбора параметров $w_1, w_2, \ldots, w_D, w_0$ модели $a(X,w)$. Задача обучения — найти параметры, которые наилучшим образом описывают истинную зависимость:

$$a(X,w) \approx \rho(X).$$

Процесс подбора оптимального параметра модели по обучающей выборке называется **обучением** *(leaning, training)* алгоритма.

Функция потерь

Этап обучения наиболее сложен. Как правило, он сводится к поиску параметров модели, доставляющих оптимальное значение заданному функционалу качества.

Функция потерь *(loss function)* — это функция $L(a(X,w), y)$, характеризующая величину ошибки алгоритма a на объекте $X \in \mathscr{X}$.

Функция потерь показывает, насколько плохо модель предсказывает ответы. Она измеряет «цену ошибки» модели на одном объекте:

$$L(\hat{y},y).$$

Виды функции потерь

Среднеквадратичная ошибка (MSE):

$$L(a(X,w), y) = (a(X,w) - y)^2$$

- сильно штрафует большие отклонения (ошибки);
- гладкая, удобна для аналитических решений;
- чувствительна к выбросам.

Средняя абсолютная ошибка (MAE):

$$L(a(X,w), y) = |a(X,w) - y|$$

- менее чувствительна к выбросам;
- но менее гладкая, сложнее для оптимизации.

Эмпирический риск

Невозможно узнать, как алгоритм поведёт себя на всех данных, но возможно сделать выводы из данных, которые есть. Поэтому ошибка минимизируется на обучающей выборке с надеждой, что алгоритм обобщит закономерности и будет работать хорошо и на новых примерах.

Эмпирическим риском называется величина средних потерь на обучающей выборке $M = \{(X_1, y_1), (X_2, y_2), \ldots, (X_m, y_m)\}$:

$$Q_M(w_1, w_2, \ldots, w_D, w_0) := \frac{1}{m}\sum_{i=1}^{m} L(a(X_i, w), y_i).$$

Минимизация эмпирического риска

$$Q_M(w_1, w_2, \ldots, w_D, w_0) := \frac{1}{m}\sum_{i=1}^{m} L(a(X_i, w), y_i)$$

Классический метод обучения, называемый **минимизацией эмпирического риска** *(empirical risk minimization, ERM),* заключается в том, чтобы найти в заданной модели алгоритм, доставляющий минимальное значение функционалу качества на заданной обучающей выборке:

$$\mu(M) = \arg\min_{w_1, w_2, \ldots, w_D, w_0} Q_M(w_1, w_2, \ldots, w_D, w_0).$$

Метод наименьших квадратов

Метод наименьших квадратов выбирает такие коэффициенты $w_1, w_2, \ldots, w_D, w_0$, чтобы сумма квадратов ошибок (разностей между предсказаниями и реальными значениями) была минимальной. В этом случае эмпирический риск:

$$Q_M(w_1, w_2, \ldots, w_D, w_0) := \frac{1}{m}\sum_{i=1}^{m}(\widehat{y}_i - y_i)^2 = \frac{1}{m}\sum_{i=1}^{m}(X_i^{\mathrm{T}} w + w_0 - y_i)^2 \longrightarrow \min_{w_1, w_2, \ldots, w_D, w_0}.$$

Или в матричном виде:

$$\mathbf{X} = \begin{pmatrix} 1 & x_{11} & x_{12} & \ldots & x_{1D} \\ 1 & x_{21} & x_{22} & \ldots & x_{2D} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & x_{m1} & x_{m2} & \ldots & x_{mD} \end{pmatrix}, \quad \mathbf{w} = \begin{pmatrix} w_0 \\ w_1 \\ \vdots \\ w_D \end{pmatrix}, \quad \mathbf{y} = \begin{pmatrix} y_1 \\ y_2 \\ \vdots \\ y_m \end{pmatrix}$$

$$\hat{\mathbf{y}} = \mathbf{X}\mathbf{w}.$$

$$Q(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

Метод наименьших квадратов

Эмпирический риск:

$$Q(\mathbf{w}) = \|\mathbf{X}\mathbf{w} - \mathbf{y}\|^2$$

или в развёрнутом виде:

$$Q(\mathbf{w}) = (\mathbf{X}\mathbf{w} - \mathbf{y})^\top (\mathbf{X}\mathbf{w} - \mathbf{y})$$

Раскрывая скобки,

$$Q(\mathbf{w}) = (\mathbf{X}\mathbf{w})^\top (\mathbf{X}\mathbf{w}) - 2\mathbf{y}^\top (\mathbf{X}\mathbf{w}) + \mathbf{y}^\top \mathbf{y}.$$

Так как $(\mathbf{X}\mathbf{w})^\top = \mathbf{w}^\top \mathbf{X}^\top$,

$$Q(\mathbf{w}) = \mathbf{w}^\top \mathbf{X}^\top \mathbf{X}\mathbf{w} - 2\mathbf{w}^\top \mathbf{X}^\top \mathbf{y} + \mathbf{y}^\top \mathbf{y}.$$

Метод наименьших квадратов

Оптимизация параметров:

$$Q(\mathbf{w}) = \mathbf{w}^\top \mathbf{X}^\top \mathbf{X}\mathbf{w} - 2\mathbf{w}^\top \mathbf{X}^\top \mathbf{y} + \cancel{\mathbf{y}^\top \mathbf{y}} \longrightarrow \min_{\mathbf{w}}$$

Условие минимума:

$$\nabla_{\mathbf{w}} Q(\mathbf{w}) = 0.$$

Расписывая градиент,

$$\nabla_{\mathbf{w}} Q(\mathbf{w}) = 2\mathbf{X}^\top \mathbf{X}\mathbf{w} - 2\mathbf{X}^\top \mathbf{y}. = 0$$

Приравнивая к нулю:

$$\mathbf{X}^\top \mathbf{X}\mathbf{w} = \mathbf{X}^\top \mathbf{y}.$$

$f(x) = x^2 - 2x + 1$

$f'(x) = 2x - 2$

$f'(x) = 0$

$2x - 2 = 0$

$x = 1$

Метод наименьших квадратов

Если матрица $\mathbf{X}^\top\mathbf{X}$ обратима, можно умножить обе части на её обратную:

$$\underbrace{(\mathbf{X}^\top\mathbf{X})^{-1}(\mathbf{X}^\top\mathbf{X})}_{E}\mathbf{w} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}.$$

Таким образом, получен явный вид решения:

$$\boxed{\mathbf{w} = (\mathbf{X}^\top\mathbf{X})^{-1}\mathbf{X}^\top\mathbf{y}}.$$

Преимущества МНК

- ✓ Аналитическое решение: есть явная формула для решения, не требующая численной оптимизации.
- ✓ Быстрое вычисление: для небольших и средних задач МНК решается напрямую через линейную алгебру.
- ✓ Хорошие статистические свойства: при выполнении предположений классической линейной модели (ошибки независимы, имеют нулевое ожидание и одинаковую дисперсию) оценки коэффициентов несмещённые, эффективные и состоятельные.

Недостатки МНК

- Чувствительность к выбросам: один выброс может сильно изменить параметры модели.
- Требует линейной зависимости: при нелинейных зависимостях МНК даёт плохие результаты.
- Неустойчивость при мультиколлинеарности: если признаки сильно коррелированы, то матрица может быть $\mathbf{X}^\top\mathbf{X}$ необратима, решение становится нестабильным, веса сильно изменяются при малых изменениях параметров.
- Проблема вычислений: брать обратные матрицы при большой числе признаков – довольно трудоёмкий процесс.

Вопросы