proglib.academy

Математика для Data Science

3. Матричные разложения

Ксения Кондаурова

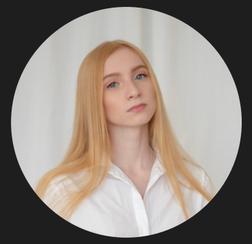

- выпускница механико-математического факультета МГУ
- преподаватель и автор курсов для бакалавриата Центрального Университета (Т-Банк)
- спикер и методист для магистратуры Edutoria (Сбербанк)
- участница конференций и научных форумов по теории вероятностей

План вебинара

Теория:

- собственные векторы и собственные значения линейного преобразования
- спектральное разложение
- ортогональные и симметричные матрицы
- сингулярное разложение

Практика в Python:

- метод главных компонент и рекомендательные системы

Литература

Математика:

- Винберг Э.Б. «Курс алгебры»
- Кострикин А.И. «Введение в алгебру. Части I-III»

Машинное обучение:

- Bishop C. M. «Pattern recognition and machine learning»

Python:

- официальная документация NumPy
- официальная документация scikit-learn

Линейный оператор

Отображение $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^m$ линейного пространства $\mathbb{R}^n$ в линейное пространство $\mathbb{R}^m$ называется **линейным оператором**, если выполнены свойства:

1) для любых $x_1, x_2 \in \mathbb{R}^n$ $\quad L(x_1 + x_2) = L(x_1) + L(x_2)$;
2) для любых $x \in \mathbb{R}^n$, $\lambda \in \mathbb{R}$ $\quad L(\lambda x) = \lambda L(x)$.

Если рассматривается линейный оператор $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^n$ из пространства $\mathbb{R}^n$ в себя, его принято называть **линейным преобразованием**.

Матрица линейного оператора

Пусть $\{e_1,\ldots,e_n\}$ – базис пространства $\mathbb{R}^n$. Применим линейное преобразование $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^n$ к базисным векторам и получим новые векторы:

$$g_k = L(e_k),\ \ k = 1,\ldots,n.$$

Их также можно разложить по базису $\{e_1,\ldots,e_n\}$:

$$g_k = \sum_{i=1}^{n} a_{ik}\ e_i,\ \ k = 1,\ldots,n,$$

где a_{ik} – i-ая координата вектора g_k.

Квадратная матрица A, состоящая из координат a_{ik} называется **матрицей линейного преобразования L в базисе $\{e_1,\ldots,e_n\}$**:

коорд. $g_k = L(e_k)$

$$A = \begin{pmatrix} a_{11} & a_{12} & \ldots & a_{1n} \\ a_{21} & a_{22} & \ldots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \ldots & a_{nn} \end{pmatrix}$$

Пример: оператор растяжения в 2 раза

$\begin{pmatrix} x \\ y \end{pmatrix} = \begin{pmatrix} 2 \\ 1 \end{pmatrix} = a \qquad L_1(a) = \begin{pmatrix} 4 \\ 2 \end{pmatrix} = \hat{a}$

Определение:

$$L_1 : \mathbb{R}^2 \to \mathbb{R}^2, \quad L_1(x, y) = (2x, 2y)$$

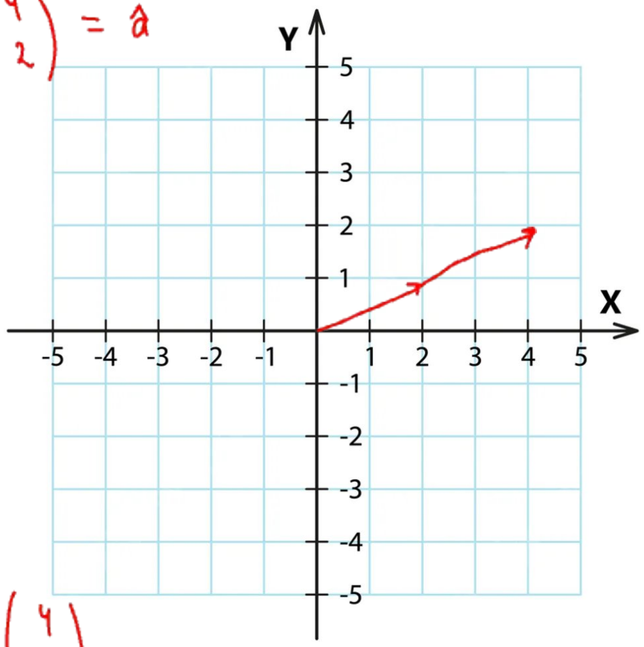

Матрица оператора:

$$L_1 = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix}$$

$e_1 = \begin{pmatrix} 1 \\ 0 \end{pmatrix} \qquad e_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$

$L_1(e_1) = \begin{pmatrix} 2 \\ 0 \end{pmatrix} \qquad L_1(e_2) = \begin{pmatrix} 0 \\ 2 \end{pmatrix}$

$\hat{a} = \begin{pmatrix} 2 & 0 \\ 0 & 2 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 4 \\ 2 \end{pmatrix}$

Пример: оператор поворота на 90° против часовой стрелки

Определение:

$$L_2 : \mathbb{R}^2 \to \mathbb{R}^2, \quad L_2(x, y) = (-y, x)$$

Матрица оператора:

$$L_2 = \begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix}$$

$$\begin{pmatrix} 0 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 2 \end{pmatrix}$$

мер: оператор поворота на 90° против
вой стрелки

Пример: оператор поворота на угол θ

Пусть $\theta \in \mathbb{R}$.

Оператор поворота на угол θ — это линейный оператор

$$R_\theta : \mathbb{R}^2 \to \mathbb{R}^2,$$

задаваемый матрицей

$$R_\theta = \begin{pmatrix} \cos\theta & -\sin\theta \\ \sin\theta & \cos\theta \end{pmatrix}$$

Действие на вектор $x = (x_1, x_2)$:

$$R_\theta x = \begin{pmatrix} x_1 \cos\theta - x_2 \sin\theta \\ x_1 \sin\theta + x_2 \cos\theta \end{pmatrix}$$

$\theta = 45°$

$$R_{45°} = \begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix}$$

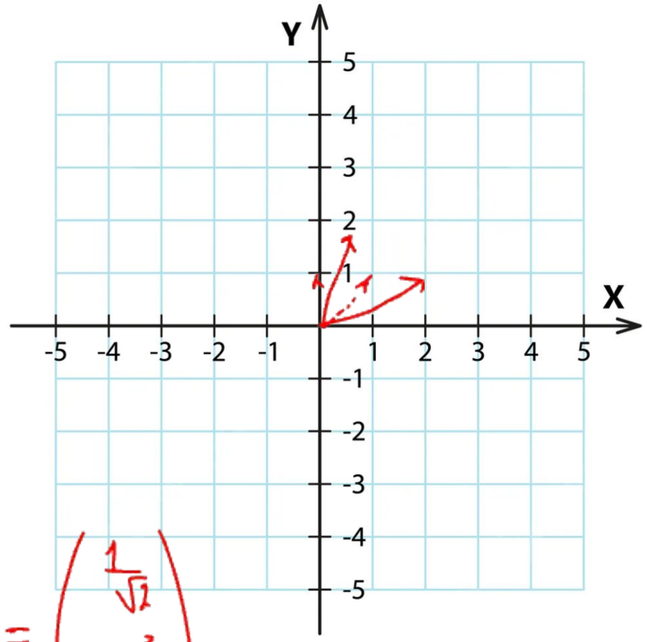

$$\begin{pmatrix} \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{3}{\sqrt{2}} \end{pmatrix}$$

$$\begin{pmatrix} & \\ & \end{pmatrix} \begin{pmatrix} 1 \\ 1 \end{pmatrix} = \begin{pmatrix} 0 \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

Пример: оператор отражения относительно оси x

Определение:

$$L_3 : \mathbb{R}^2 \to \mathbb{R}^2, \quad L_3(x, y) = (x, -y)$$

Матрица оператора:

$$L_3 = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$

$$\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix} \begin{pmatrix} 2 \\ 1 \end{pmatrix} = \begin{pmatrix} 2 \\ -1 \end{pmatrix}$$

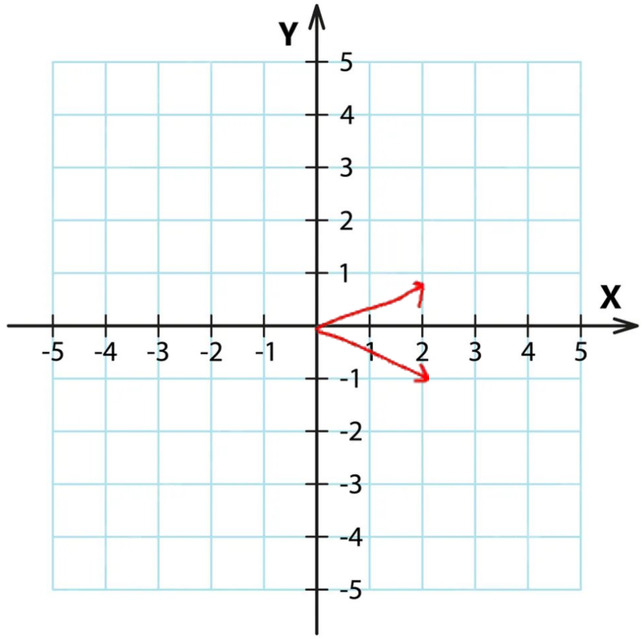

Пример: линейная регрессия

Модель:

$$\hat{y} = Xw$$

Отображение

$$T(w) = Xw$$

является линейным оператором из пространства параметров в пространство предсказаний.

Пример: оператор проекции на прямую

Определение:

$$P:\ \mathbb{R}^2 \to \mathbb{R}^2, \qquad P(x) = \frac{(x,u)}{(u,u)}\,u, \quad u \neq 0$$

Матрица оператора:

$$P = \frac{1}{u_1^2 + u_2^2}\begin{pmatrix} u_1^2 & u_1 u_2 \\ u_1 u_2 & u_2^2 \end{pmatrix}$$

(проекция на прямую, натянутую на вектор $u = (u_1, u_2)$)

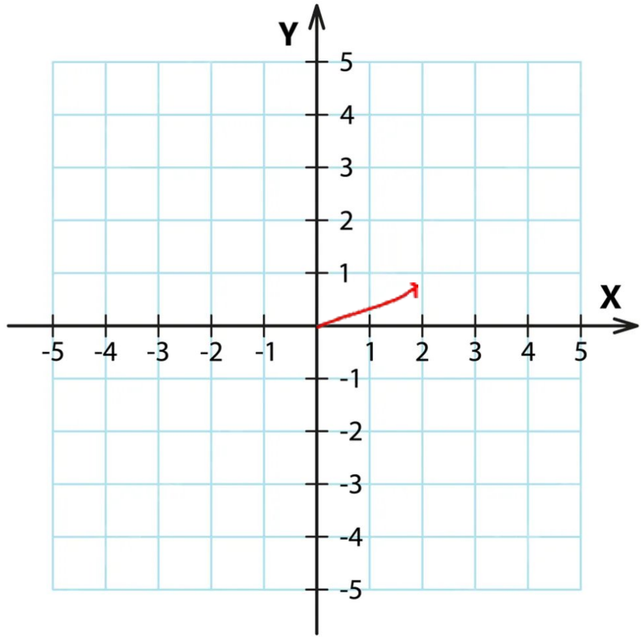

Пример: МНК

Оценка методом МНК имеет вид:

$$\hat{y} = Xw = X\boxed{(X^T X)^{-1} X^T y}$$

Оператор

$$P = X(X^T X)^{-1} X^T$$

ортогональным проектором на пространство всех линейных комбинаций столбцов X.

proglib.academy

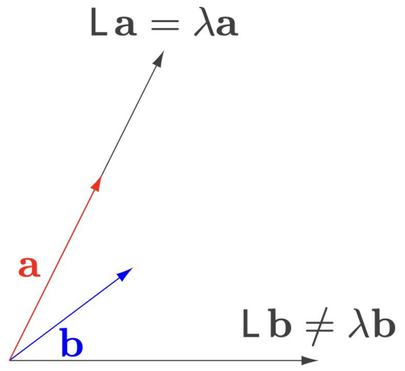

Собственный вектор

Если для преобразования $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^n$ найдётся <u>ненулевой</u> вектор $v \neq 0$, $v \in \mathbb{R}^n$ и число $\lambda \in \mathbb{R}$ такие, что

$$Lv = \lambda \cdot v,$$

то

- вектор v называется **собственным вектором**;
- число λ называется **собственным значением**.

Собственными значениями и собственными векторами матрицы A размера $n \times n$ называются собственные значения и векторы соответствующего линейного преобразования L.

! Собственные векторы и собственные значения не зависят от выбора базиса.

Поиск собственных значений

$$\begin{vmatrix} 1-\lambda & 2 \\ -3 & 6-\lambda \end{vmatrix} = (1-\lambda)(6-\lambda) + 6 = 0$$

Пусть дана квадратная матрица A размера $n \times n$. Все собственные значения λ удовлетворяют условию:

$$Av = \lambda \cdot v, \ v \neq 0.$$

$$A = \begin{pmatrix} 1 & 2 \\ -3 & 6 \end{pmatrix}$$

Переносим $\lambda \cdot v$ в левую часть:

$$(A - \lambda I)\, v = 0.$$

$$\begin{pmatrix} 1 & 2 \\ -3 & 6 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \lambda \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$$

Здесь I — единичная матрица $n \times n$.

$$\begin{cases} v_1 + 2v_2 = \lambda v_1 \\ -3v_1 + 6v_2 = \lambda v_2 \end{cases}$$

Это система линейных уравнений относительно v. Чтобы система имела ненулевое решение $v \neq 0$ определитель матрицы должен быть равен нулю:

$$det(A - \lambda I) = 0.$$

$$\begin{cases} v_1 - \lambda v_1 + 2v_2 = 0 \\ -3v_1 + 6v_2 - \lambda v_2 = 0 \end{cases}$$

$$A - \lambda I = \begin{pmatrix} 1 & 2 \\ -3 & 6 \end{pmatrix} - \lambda \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} = \begin{pmatrix} 1-\lambda & 2 \\ -3 & 6-\lambda \end{pmatrix}$$

$$\begin{cases} (1-\lambda)v_1 + 2v_2 = 0 \\ -3v_1 + (6-\lambda)v_2 = 0 \end{cases}$$

Характеристический многочлен

$(1-\lambda)(6-\lambda)+6=0$

$6-6\lambda-\lambda+\lambda^2+6=0$

$\lambda^2-7\lambda+12=0$

$D=49-48=1$

$\lambda_1=\frac{+7+1}{2}=+3$

$\lambda_2=+4$

Многочлен

$$p_A(\lambda)=det(A-\lambda I)$$

называется **характеристическим многочленом** матрицы A.

Собственные значения — это корни характеристического многочлена λ_i.

Для каждого найденного собственного значения λ_i решается система относительно v:

$$(A-\lambda_i I)\,v=0.$$

Решения этой системы (любые ненулевые векторы v_i) — это собственные векторы, соответствующие собственным значениям λ_i.

$$\begin{pmatrix} 3 & 0 \\ 0 & 4 \end{pmatrix}$$

Пример

Найти собственные значения и собственные векторы матрицы A.

$$A = \begin{pmatrix} 1 & 2 \\ -3 & 6 \end{pmatrix}$$

$\lambda_1 = 3$

$$\begin{pmatrix} 1 & 2 \\ -3 & 6 \end{pmatrix} \begin{pmatrix} v_1 \\ v_2 \end{pmatrix} = \begin{pmatrix} 3v_1 \\ 3v_2 \end{pmatrix}$$

$$\left(\begin{array}{cc|c} -2 & 2 & 0 \\ -3 & 3 & 0 \end{array}\right) \quad \left(\begin{array}{cc|c} -1 & 1 & 0 \end{array}\right) \quad v = \begin{pmatrix} 1 \\ 1 \end{pmatrix} \quad v^1 = \begin{pmatrix} \frac{1}{\sqrt{2}} \\ \frac{1}{\sqrt{2}} \end{pmatrix}$$

$$|v| = \sqrt{1^2 + 1^2} = \sqrt{2}$$

$$\lambda_2 = 4 \rightsquigarrow v^2 = \begin{pmatrix} 2 \\ 3 \end{pmatrix} \quad v^2 = \begin{pmatrix} \frac{2}{\sqrt{13}} \\ \frac{3}{\sqrt{13}} \end{pmatrix}$$

Линейная независимость собственных векторов

Утверждение. Если A — квадратная матрица, а v_1, v_2 — собственные векторы, соответствующие разным собственным значениям $\lambda_1 \neq \lambda_2$, то векторы v_1, v_2 линейно независимы.

Д-т: от противн.

$v_2 = c v_1, \quad c \in \mathbb{R}, c \neq 0$

$Av_2 = \lambda_2 v_2 = \lambda_2 c v_1$

$Av_2 = A(cv_1) = cAv_1 = c\lambda_1 v_1$

$\Rightarrow c\lambda_2 v_1 = c\lambda_1 v_1$

$c(\lambda_2 - \lambda_1) v_1 = 0$

$c(\lambda_2 - \lambda_1) = 0$

$\lambda_2 - \lambda_1 = 0$

$\lambda_2 = \lambda_1$. Прот.

Спектральное разложение

Допустим, у матрицы A размера $n \times n$ нашлось n линейно независимых собственных векторов $\{\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n\}$, которым соответствуют собственные значения $\{\lambda_1, \lambda_2, \dots, \lambda_n\}$.
Запишем все собственные векторы в матрицу P столбцами друг за другом, а в матрицу D поместим все собственные числа на главную диагональ.

$$P = \begin{pmatrix} | & | & & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \\ | & | & & | \end{pmatrix}, \; D = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ 0 & 0 & \dots & 0 \\ 0 & 0 & \dots & \lambda_n \end{pmatrix}$$

Тогда справедливо **спектральное разложение:**

$$A = P\,D\,P^{-1}$$

Идея д-ва: $\{e_1, \dots e_n\}$ – базис

$A \cdot | Pe_i = v_i$

$P^{-1} | APe_i = Av_i = \lambda_i v_i$

$P^{-1}APe_i = \lambda_i \underbrace{P^{-1}v_i}_{e_i}$

$P^{-1}APe_i = \lambda_i e_i$

Пример

Найти спектральное разложение матрицы A.

$$A = \begin{pmatrix} 1 & 2 \\ -3 & 6 \end{pmatrix}$$

$$A = \overbrace{\begin{pmatrix} 1 & 2 \\ 1 & 3 \end{pmatrix}}^{P} \overbrace{\begin{pmatrix} 3 & 0 \\ 0 & 4 \end{pmatrix}}^{D} \overbrace{\begin{pmatrix} 1 & 2 \\ 1 & 3 \end{pmatrix}^{-1}}^{P^{-1}}$$

$$\begin{pmatrix} 1 & 2 \\ 1 & 3 \end{pmatrix}^{-1} = \begin{pmatrix} 3 & -2 \\ -1 & 1 \end{pmatrix}$$

Критерии вырожденности

Матрица A размера $n \times n$ называется **вырожденной**, если:

1. $\det A = 0$;
2. Система $A\mathbf{x} = \mathbf{0}$ имеет бесконечное количество решений;
3. Система $A\mathbf{x} = \mathbf{b}$ имеет ноль или бесконечное количество решений;
4. $rank\ A < n$;
5. Столбцы A линейно зависимы;
6. Строки A линейно зависимы;
7. A^{-1} не существует;
8. У матрицы A есть собственное значение $\lambda = 0$.

Евклидово линейное пространство

Линейное пространство E над полем $\mathbb{R}$ называется **евклидовым**, если на парах его векторов определена функция $E \times E \to \mathbb{R}$, удовлетворяющая условиям:

1) (билинейность)
   для любых $x_1, x_2, y \in E$, $\lambda_1, \lambda_2 \in \mathbb{R}$ $\quad (\lambda_1 x_1 + \lambda_2 x_2, y) = \lambda_1 (x_1, y) + \lambda_2 (x_2, y)$;
   для любых $x, y_1, y_2 \in E$, $\mu_1, \mu_2 \in \mathbb{R}$ $\quad (x, \mu_1 y_1 + \mu_2 y_2) = \mu_1 (x, y_1) + \mu_2 (x, y_2)$;
2) (симметричность)
   $(x, y) = (y, x)$;
3) (положительная определённость)
   $(x, x) \geq 0$, причём $(x, x) = 0$ только при $x = 0$

Эту функцию называют **скалярным произведением**.

Линейное пространство $\mathbb{R}^n$ со знакомым скалярным произведением $(x, y) = x_1 y_1 + \ldots x_n y_n$ для векторов $x = (x_1, \ldots, x_n)$, $y = (y_1, \ldots, y_n)$ является евклидовым.

Ортогональность векторов

E – евклидово линейное пространство.
Векторы $x,y \in E$ называются **ортогональными**, если $(x,y) = 0$.

Базис $\{e_1,\ldots,e_n\}$ евклидова пространства E называется **ортогональным**, если векторы $e_1,\ldots,e_n$ попарно ортогональны.

Число $|x| = \sqrt{(x,x)}$ называется **длиной** вектора $x \in E$.

Базис $\{e_1,\ldots,e_n\}$ евклидова пространства E называется **ортонормированным**, если все векторы $e_1,\ldots,e_n$ имеют единичную длину.

Угол между векторами $x,y \in E$ определяется как

$$\cos \angle (x,y) = \frac{(x,y)}{|x|\,|y|}.$$

Пример: стандартный базис $\mathbb{R}^2$

$$e_1 = (1, 0), \quad e_2 = (0, 1)$$

$(e_1, e_2) = 0$

$|e_1| = \sqrt{(e_1, e_1)} = 1$

$|e_2| = 1$

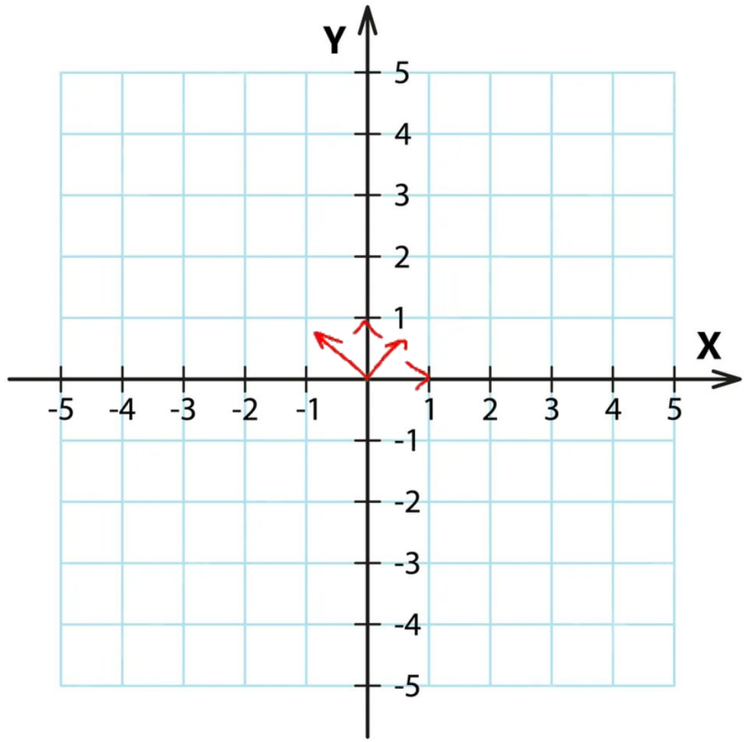

Ортогональные преобразования и ортогональные матрицы

Линейное преобразование $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^n$ евклидова линейного пространства $\mathbb{R}^n$ в себя называется **ортогональным**, если оно сохраняет скалярное произведение, то есть для любых $x,y \in \mathbb{R}^n$

$$(Lx,Ly) = (x,y).$$

Квадратная матрица C называется **ортогональной**, если $C^T = C^{-1}$, то есть $C^T C = CC^T = E$, где E – единичная матрица.

Определитель ортогональной матрицы единичен по модулю: $\det C = \pm 1$.

Эквивалентные определения

Линейное преобразование $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^n$ является ортогональным, если выполнено хотя бы одно из следующих свойств:

1. Оно сохраняет длины векторов, то есть для любого $x \in \mathbb{R}^n$

$$|Lx| = |x|\,.$$

2. Оно сохраняет углы, то есть для любых $x, y \in \mathbb{R}^n$

$$\cos\angle(Lx, Ly) = \cos\angle(x, y)\,.$$

3. В каком-либо (а значит, и в любом) ортонормированном базисе матрица C преобразования L является ортогональной.

Пример: ортогональные преобразования в $\mathbb{R}^2$

1. Отражение относительно x-оси:
$$\begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}^T = \begin{pmatrix} 1 & 0 \\ 0 & -1 \end{pmatrix}$$
2. Отражение относительно y-оси:
$$\begin{pmatrix} -1 & 0 \\ 0 & 1 \end{pmatrix}$$
3. Отражение относительно линии $y = x$:
$$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$$

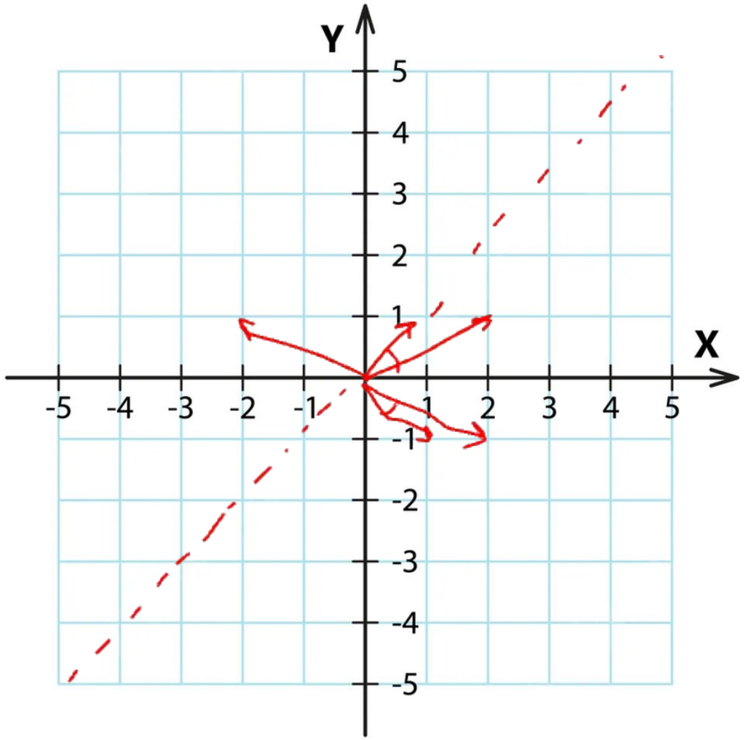

Пример: ортогональные преобразования в $\mathbb{R}^2$

В случае евклидовой плоскости всякое *собственное* ортогональное преобразование (определитель равен 1) является поворотом на некоторый угол ϕ, и его матрица в любом ортонормированном базисе имеет вид:

$$\begin{pmatrix} \cos\varphi & \sin\varphi \\ -\sin\varphi & \cos\varphi \end{pmatrix}.$$

Всякое *несобственное* ортогональное преобразование (определитель равен –1) является композицией поворота и отражения, и его матрица имеет вид:

$$\begin{pmatrix} \cos\varphi & \sin\varphi \\ \sin\varphi & -\cos\varphi \end{pmatrix}.$$

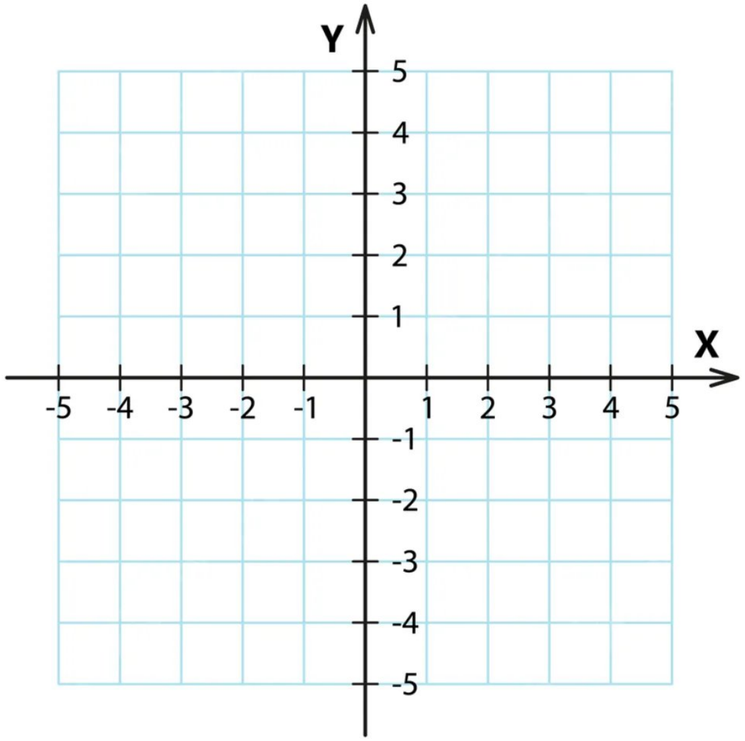

Симметричные преобразования

Линейное преобразование $L\colon \mathbb{R}^n \longrightarrow \mathbb{R}^n$ евклидова линейного пространства $\mathbb{R}^n$ в себя называется **симметричным (самосопряжённым)**, если для любых $x, y \in \mathbb{R}^n$

$$(Lx, y) = (x, Ly).$$

$$(Lx, y) = (x, L^{+}y)$$

$$\begin{pmatrix} 1 & 3 \\ 3 & 2 \end{pmatrix}$$

Квадратная матрица A называется **симметричной**, если $A = A^T$.

В ортонормированном базисе матрица самосопряжённого линейного преобразования симметрична.

Пример: симметричные преобразования в $\mathbb{R}^2$

Матрица A	Геометрическое действие
$\begin{pmatrix} 2 & 0 \\ 0 & 3 \end{pmatrix}$	Растяжение вдоль осей x и y (по-разному)
$\begin{pmatrix} 0 & 1 \\ 1 & 0 \end{pmatrix}$	Отражение относительно прямой $y = x$
$\begin{pmatrix} 3 & 2 \\ 2 & 4 \end{pmatrix}$	Растяжение с наклоном вдоль собственных направлений
$\begin{pmatrix} 1 & 0 \\ 0 & 0 \end{pmatrix}$	Проекция на ось x

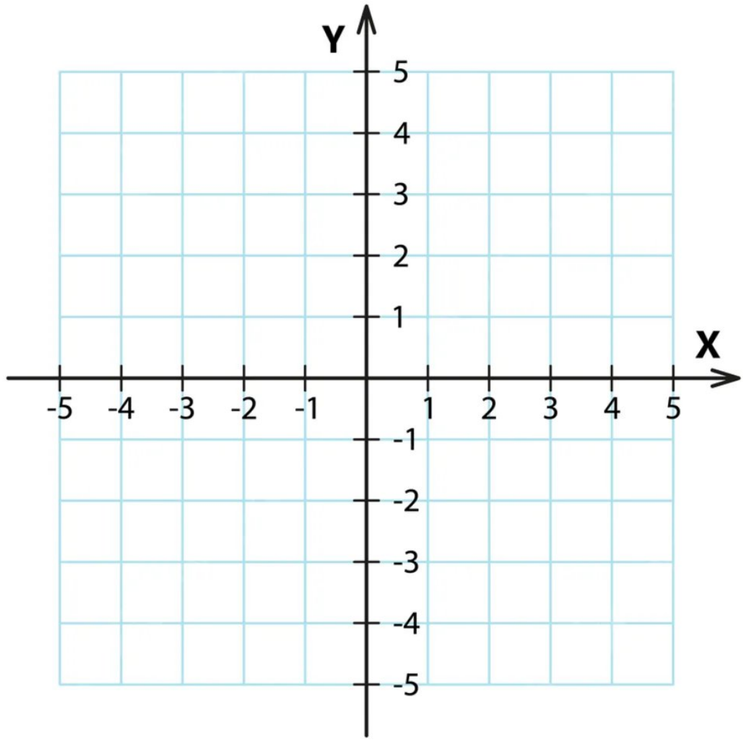

Спектральное разложение

Утверждение. У симметричной матрицы A размера $n \times n$ найдётся n ортогональных собственных векторов единичной длины.

С их помощью матрица A представима в виде:

$$A = P\,D\,P^{-1},$$

$$\begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 2 & 0 & 0 \\ 0 & 0 & 3 & 0 \\ 0 & 0 & 0 & 4 \end{pmatrix}$$

где

$$P = \begin{pmatrix} | & | & & | \\ \mathbf{v}_1 & \mathbf{v}_2 & \dots & \mathbf{v}_n \\ | & | & & | \end{pmatrix}, \; D = \begin{pmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ 0 & 0 & \cdots & 0 \\ 0 & 0 & \dots & \lambda_n \end{pmatrix}$$

$\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ – собственные вектора, $\lambda_1, \lambda_2, \dots, \lambda_n$ – собственные значения.

Жорданова нормальная форма

Что делать, если у матрицы A размера $n \times n$ меньше, чем n независимых собственных векторов?

Утверждение. Любая квадратная матрица A представима в виде

$$A = P\,J\,P^{-1},$$

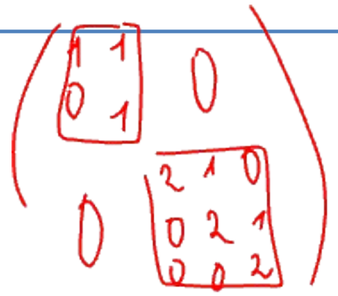

где **жорданова нормальная форма** J содержит на диагонали **жордановы клетки** J_i:

$$J = \begin{pmatrix} J_1 & 0 & 0 & 0 \\ 0 & J_2 & 0 & 0 \\ 0 & 0 & \ddots & 0 \\ 0 & 0 & 0 & J_k \end{pmatrix}, \quad J_i = \begin{pmatrix} \lambda_i & 1 & 0 & \cdots & 0 \\ 0 & \lambda_i & 1 & \cdots & 0 \\ \vdots & \vdots & \ddots & \ddots & \vdots \\ 0 & 0 & \cdots & \lambda_i & 1 \\ 0 & 0 & \cdots & 0 & \lambda_i \end{pmatrix}$$

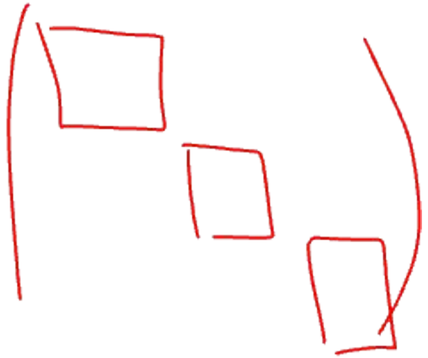

Сингулярное разложение (SVD)

Утверждение. У любой матрицы A размера $m \times n$ существует сингулярное разложение:

$$A = U \Sigma V^T,$$

где U – ортогональная матрица размера $m \times m$, $UU^T = U^TU = E$

Σ – прямоугольная диагональная матрица размера $m \times n$, на диагонали которой стоят **сингулярные числа** $\sigma_1 \geq \sigma_2, \geq \ldots \geq 0$ – корни из собственных значений матрицы A^TA

V – ортогональная матрица размера $n \times n$. $VV^T = V^TV = E$

$$U = \begin{pmatrix} | & & | \\ u_1 & \ldots & u_m \\ | & & | \end{pmatrix}, \quad V = \begin{pmatrix} | & & | \\ v_1 & \ldots & v_n \\ | & & | \end{pmatrix}$$

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & 0 & \ldots \\ 0 & \sigma_2 & 0 & \ldots \\ 0 & 0 & \sigma_3 & \ldots \\ \vdots & \vdots & \vdots & \ddots \end{pmatrix}$$

Сингулярное разложение (SVD)

Если $m \geq n$, то SVD-разложение примет вид:

$$A = \begin{pmatrix} | & & | \\ \mathbf{u}_1 & \dots & \mathbf{u}_n \\ | & & | \end{pmatrix} \cdot \begin{pmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & \sigma_k \\ 0 & 0 & \dots & 0 \\ \dots & \dots & \dots & \dots \\ 0 & 0 & \dots & 0 \end{pmatrix} \begin{pmatrix} — & \mathbf{v}_1^T & — \\ & \vdots & \\ — & \mathbf{v}_k^T & — \end{pmatrix}$$

Геометрический смысл SVD

SVD-разложение описывает, как матрица A преобразует пространство $\mathbb{R}^n$ в пространство $\mathbb{R}^m$:

1) сначала выполняет поворот/отражение с помощью V^T,
2) затем растяжение/сжатие вдоль осей на σ_i,
3) и потом ещё один поворот/отражение через U.

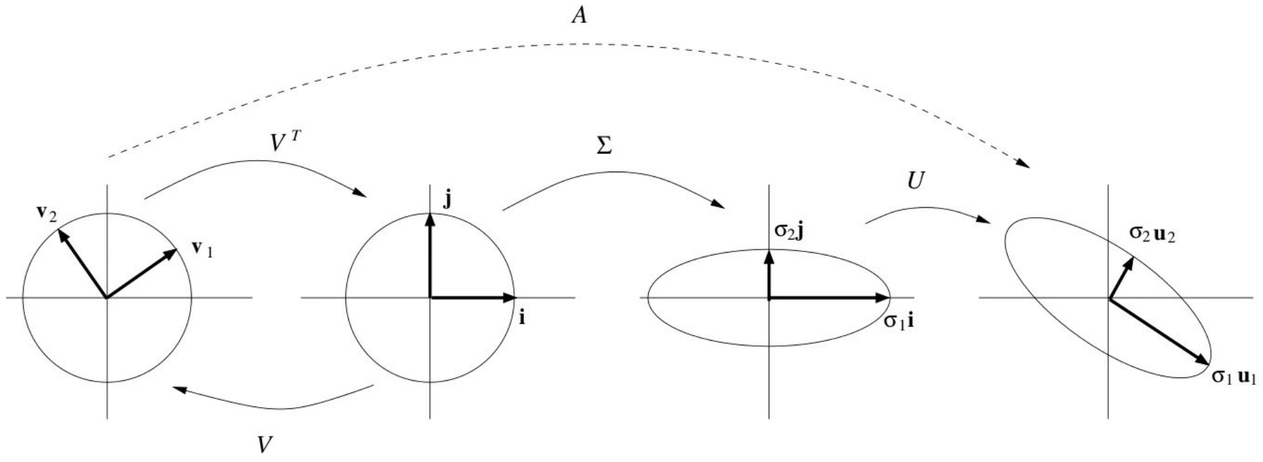

$$A = U \Sigma V^T = \text{(поворот)}\circ\text{(растяжение)}\circ\text{(поворот)}$$

Свойства SVD

1. Все сингулярные числа $\sigma_i \geq 0$.
2. Ранг матрицы A равен числу ненулевых σ_i.
3. Существует для любой матрицы, в отличие от спектрального разложения.

Интуиция: что делает SVD?

Сингулярное разложение

$$A = U \Sigma V^T,$$

представляет матрицу A любого размера как комбинацию нескольких «главных направлений», вдоль которых данных момент содержится наибольшая информация.

- Большие сингулярные числа σ_i – это главные компоненты, несущие основную информацию про структуру данных.
- Маленькие сингулярные числа σ_i – это шум, детали, случайные отклонения.

Снижение размерности через SVD

Снижение размерности — это процесс преобразования многомерных данных в пространство меньшей размерности. Он позволяет сократить количество переменных, сохранив те, которые вносят основной вклад в вариативность данных. Этот подход облегчает анализ, ускоряет вычисления и улучшает работу алгоритмов машинного обучения.

Пусть $r = rank(A)$. Если мы возьмём только первые $k \leq r$ самых больших сингулярных чисел, получим «приближение» низкого ранга:

$$A \approx A_k = U_k \Sigma_k V_k^T,$$

где U_k содержит первые столбцов из U,
Σ_k – первые $k \times k$ диагональных элементов из Σ,
V_k – первые столбцов из V.

proglib.academy

Метод главных компонент (PCA)

Метод главных компонент *(Principal component analysis, PCA)* – один из основных методов сокращения размерности данных, используемых в машинном обучении.

Сокращение размерности применяется для того, чтобы найти наиболее важные признаки в *альтернативном* признаковом пространстве.

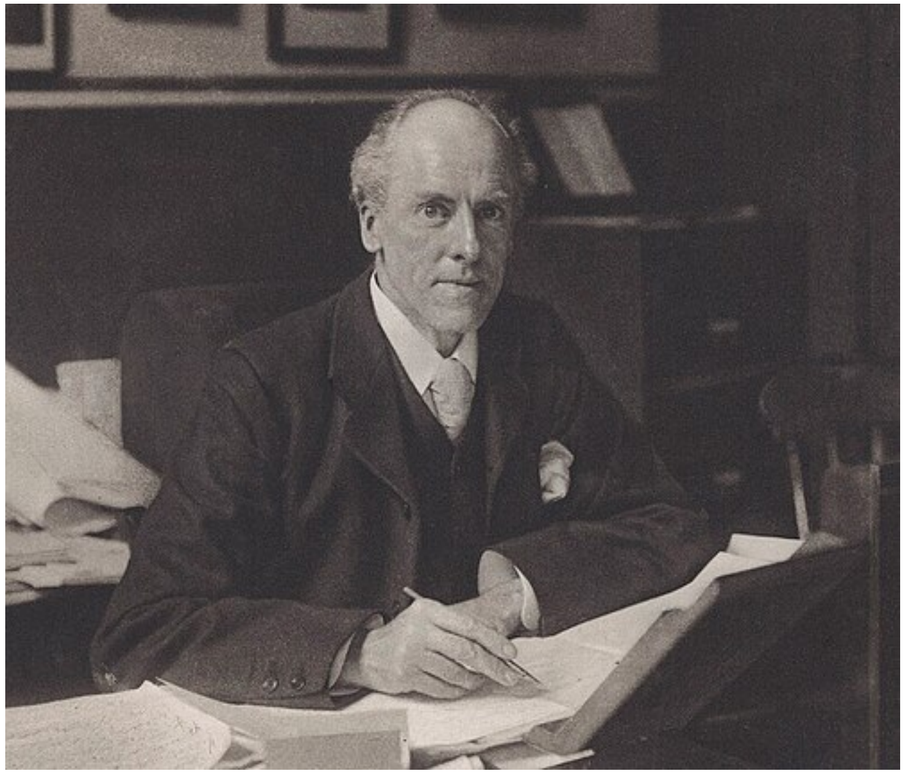

Метод главных компонент был предложен в 1901 году Карлом Пирсоном. Карл Пирсон - один из наиболее известных ученых, занимавшихся математической статистикой. Широко известен предложенный им способ количественного измерения статистической взаимосвязи двух или более случайных величин - коэффициент корреляции Пирсона, или просто коэффициент корреляции.

proglib.academy

Метод главных компонент (PCA)

Характеристики объекта могут быть сильно взаимосвязаны, что затрудняет анализ. PCA позволяет найти те направления в данных, где находится основная часть их вариативности. Эти направления и называются **главными компонентами**.

Первая главная компонента — это направление, вдоль которого разброс данных максимален. Она содержит максимальную информацию о различиях в данных. Вторая главная компонента перпендикулярна первой и содержит вторую по значимости часть вариативности. Каждая следующая компонента объясняет всё меньшую часть общей дисперсии данных.

Важно отметить, что главные компоненты — это не реальные измерения, которые изначально есть в данных. Это искусственно созданные оси, которые помогают представить данные более компактно и осмысленно.

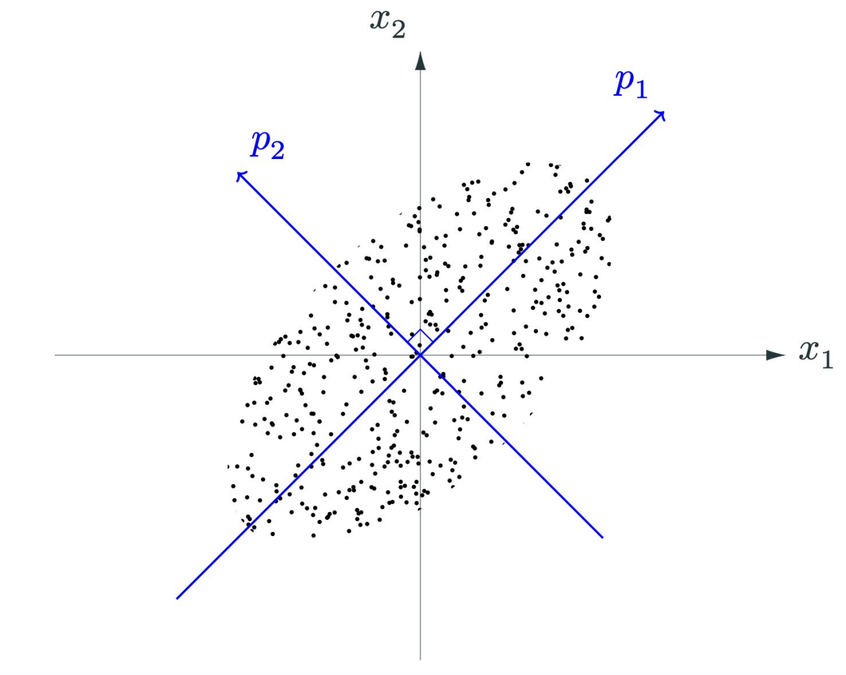

Применение PCA

1. Идентифицировать скрытые паттерны. Например, в медицинских исследованиях PCA может выделить сочетания симптомов или показателей, по которым наиболее сильно различаются группы пациентов.

2. Упростить модели. Многомерные данные часто содержат коррелированные переменные. PCA уменьшает их количество, сохраняя основную информацию, что облегчает построение моделей машинного обучения.

3. Улучшить визуализацию. Даже самые сложные наборы данных можно сделать более понятными, сведя их к двум-трём главным компонентам и представив в виде графиков.

Интерпретация PCA

Пусть фактор X_1 описывает максимальную скорость автомобиля, а фактор X_2 - объем его двигателя. Некоторое агентство провело исследование и заметило две следующие закономерности:

- Никто не производит автомобили с большим объемом двигателя и маленькой максимальной скоростью, или же наоборот. Обычно объем двигателя коррелирует с максимальной скоростью.

- Предыдущий вывод объясняется тем, что дорогие машины имеют лучшие характеристики по обоим факторам, а дешевые - худшие также по обоим. Бывают небольшие отклонения от этой закономерности, но они статистически незначимы.

Интерпретация PCA

Задача: предсказать стоимость автомобиля на основании факторов X_1 и X_2.

Сумма $X_1 + X_2$ содержит много информации, поскольку у дорогих машин она окажется большой, а у дешевых - маленькой. А вот признак $X_1 - X_2$ окажется совершенно не информативным, ведь и для дорогих машин, и для дешевых это значение будет низким в силу первого наблюдения.

То есть от признаков X_1 и X_2 разумно перейти к признакам $Y_1 = X_1 + X_2$ и $Y_2 = X_1 + X_2$, среди которых интересен только признак Y_1.

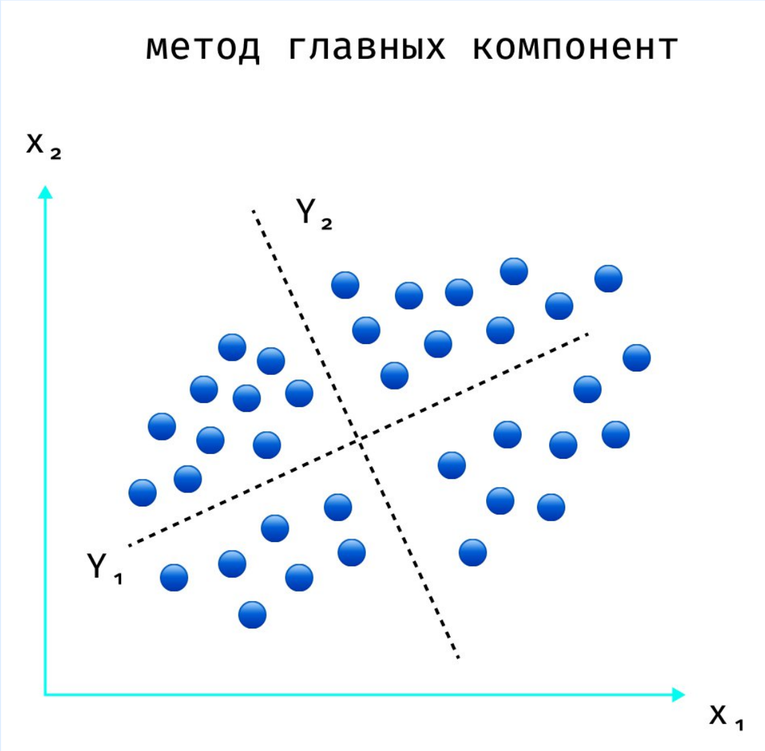

proglib.academy

Пример: SVD и рекомендательные системы

строки → пользователи
столбцы → фильмы (или товары)
числа → оценки (от 1 до 5, 0 = неизвестно)

Пользователь	Фильм 1	Фильм 2	Фильм 3	Фильм 4
A	5	3	0	1
B	4	0	0	1
C	1	1	0	5
D	1	0	0	4
E	0	1	5	4

Задача: предсказать недостающие значения (0), т.е. угадать, что пользователь поставил бы фильму, если бы посмотрел его.

Пример: SVD и рекомендательные системы

Матрица оценок размера 5×4:

$$R = \begin{pmatrix} 5 & 3 & 0 & 1 \\ 4 & 0 & 0 & 1 \\ 1 & 1 & 0 & 5 \\ 1 & 0 & 0 & 4 \\ 0 & 1 & 5 & 4 \end{pmatrix}$$

Строим приближение:

$$R \approx U_k \Sigma_k V_k^T$$

- U_i – строка из U_k, вектор длины k, который отражает предпочтений пользователя i
- V_j – столбец из V_k, вектор длины k, который отражает характеристики фильма j

$\hat{r}_{ij} = \boldsymbol{U_i \Sigma_k V_j^T}$ **– предсказанный рейтинг**

Пример: SVD и рекомендательные системы

После применения SVD система находит скрытые факторы пользователей и фильмов, а затем восстанавливает «приближённую» матрицу:

Пользователь	Фильм 1	Фильм 2	Фильм 3	Фильм 4
A	5.0	3.0	**2.1**	**1.8**
B	4.0	**2.5**	**1.9**	2.0
C	**1.8**	**1.9**	5.0	4.0

Интерпретация:
Пользователей A, вероятно, поставил бы фильму 3 оценку 2.1, а фильму 4 – оценку 1.8.

Вопросы