

ML для старта в Data Science

## **4. Линейные методы классификации**

Жарова Мария

# План занятия, теория + практика

- От регрессии к классификации
- Разбор алгоритма логистической регрессии
- Основы многоклассовой классификации
- Метрики классификации

*Пишите вопросы в чат в любое время!  
Если писать много – обсудим голосом в  
специальных перерывах :)*

# От регрессии к классификации

# Постановка задачи классификации

**Задача классификации** заключается в предсказании *дискретных значений целевой переменной* или *вероятностей классов* на основе входных признаков.

**Главное отличие от задачи регрессии:**

- в регрессии таргет - непрерывная числовая
- в классификации таргет - дискретная переменная

PS: в классификации таргетом может быть категориальный признак (как номинальный, так и порядковый); перед начало обучения его кодируют некоторым числом.

# Виды классификации

## **Бинарная классификация (2 класса):**



- определение, является ли электронное письмо спамом или не спамом;
- прогнозирование, выздоровеет ли пациент после операции или нет;
- определение, является ли транзакция мошеннической или нет и т. д.

## **Многоклассовая классификация (3+ класса):**

- Распознавание вида цветка (Iris dataset)
- Классификация изображений рукописных цифр (MNIST)
- Классификация отзывов по тональности

# Бинарная классификация

**Цель:** разделить все объекты обучающей выборки на 2 класса == наилучшим образом провести разделяющую прямую/плоскость/гиперплоскость.



# От регрессии к классификации

*На примере бинарной классификации:*

Нужно преобразовать непрерывный выход модели в дискретное значение класса / вероятность класса.

**Идея:** придумать функцию, которая бы переводила непрерывные значения в дискретные – **функцию активации.**

# Активация “функция порога”

Простейший вариант функции активации – функция порога.

Она возвращает 1, если выход модели больше определенного порога (threshold), и 0 или -1 в противном случае.

$$y = \begin{cases} 1 & \text{если } w \cdot x + b \geq \text{threshold} \\ 0 \text{ или } -1 & \text{иначе} \end{cases}$$


Таким образом делаем переход от задачи регрессии к задаче классификации.



# Геометрическая интерпретация

**Гиперплоскость** — это  $n$ -мерное обобщение понятия прямой или плоскости в пространстве большей  $(n+1)$  размерности.

Она определяется уравнением, которое состоит из суммы произведений коэффициентов на переменные, равной некоторой константе.



Для получения разделяющей гиперплоскости в задаче линейной классификации можно использовать **вектор нормали**.

*Вектор нормали направлен в сторону положительного класса.*

# Геометрическая интерпретация


Формализуем понятие вектора нормали:

$$w = (w_1, w_2, \dots, w_d),$$

где  $d$  — число признаков,

$w_1, w_2, \dots, w_d$  — коэффициенты модели.

Если  $x_i \cdot w \geq 0$  — объект относится к положительному классу; иначе — к отрицательному.




# Отступ (margin)

– это мера того, насколько уверена модель в своем прогнозе для конкретного объекта.

**Больше отступ == больше уверенность!**

$$M(x_i, y_i) = y_i * x_i \cdot w,$$

здесь  $y_i$  – метка класса (-1 или +1).



# Функции потерь # 1

**Функция потерь Хинджа** – максимизирует отступ между классами:

$$L(y, \hat{y}) = \max(0, 1 - y\hat{y}),$$

где  $\max$  – функция, возвращающая максимальное значение из двух аргументов,  $y$  – истинная метка класса (-1 или 1), а  $\hat{y}$  – предсказанная вероятность для класса 1.

- 0 – если предсказание верно,
- иначе значение, пропорциональное расстоянию между предсказанием и истинной меткой класса.


# Разбор алгоритма логистической регрессии

# Идея логрегрессии


Линейная регрессия с функцией активации **сигмоида** (логистическая функция):

$$\sigma(X, w) = \frac{1}{1 + e^{-X \cdot w}},$$


*Переводит интервал  $(-\infty, +\infty)$  в отрезок  $[0, 1]$   $\Rightarrow$  предсказание модели  $\Rightarrow$  вероятность принадлежности классу 1.*




Исходные данные




Предсказания до сигмоиды



Сравнение предсказаний с реальными метками



Финальные предсказания с порогом 0.5



# Математически

Функция потерь при обучении Г.С. – кросс-энтропия:

$$L(y, \hat{y}) = - [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})].$$

где  $y$  – истинная метка класса (0 или 1),  $X$  – вектор признаков,  $w$  – веса модели



# Математически: почему так?

$L(y, \hat{y}) = - [y \log(\hat{y}) + (1 - y) \log(1 - \hat{y})]$ . - лог-лосс или бинарная кросс-энтропия

## Цель обучения – получить:

- вероятность, близкую к 1, для объектов положительного класса;
- вероятность, близкую к 0, для объектов отрицательного класса.

## Поэтому должно выполняться:

- Для объектов положительного класса должно выполняться:

$$\sigma(x \cdot w) \rightarrow 1, x \cdot w \rightarrow +\infty$$

- Для объектов отрицательного класса должно выполняться:

$$\sigma(x \cdot w) \rightarrow 0, x \cdot w \rightarrow -\infty$$

*а логарифм “усиливает” штраф за неверное предсказание*

# Основы многоклассовой классификации

# Разновидности м. классификации

**Выделяют 3 подхода к построению многоклассовой классификации:**


- *Один против всех (OvA)* — отдельная модель для каждого класса, выбирается класс с наивысшей вероятностью.
- *Один против одного (OvO)* — модель для каждой пары классов, класс определяется голосованием моделей.
- *Многоклассовая логистическая регрессия* — одна модель предсказывает вероятности для всех классов, обучается с помощью кросс-энтропии.

# Один против всех (OvA)

Обучает отдельную модель для каждого класса, разделяя его от всех остальных.

Для классификации применяются все модели, выбирается класс с наивысшей вероятностью.

Метод удобен для любого бинарного классификатора и при малых выборках, но может ошибаться при пересечении классов.




# Один против одного (OvO)

Обучает модель для каждой пары классов, разделяя их между собой.

Для классификации все модели голосуют, класс с наибольшим числом голосов выбирается.

Метод точнее OvA, но требует больше моделей и вычислений.



# Многоклассовая лог. регрессия

**Идея:** используем *просто кросс-энтропию* (не бинарную!)

$$\text{Loss} = - \sum_i \sum_k y_{i,k} \log(\hat{y}_{i,k})$$

Вместо активации сигмоиды используем **softmax (софтмакс)** – это функция, которая преобразует вектор произвольных действительных чисел в вектор вероятностей, где сумма всех вероятностей равна 1.

$$\text{softmax}(z_i) = \frac{e^{z_i}}{\sum_{j=1}^n e^{z_j}},$$

PS: сигмоида - частный случай для 2-х классов:  $\sigma(z) = \frac{e^z}{e^z + e^0}$

# Софтмакс: пример

## Пример классификации на 3 класса:

Пусть модель возвращает вектор  $[1.5, 2.3, 0.8]$  для какого-либо объекта – это называется **ЛОГИТЫ**.

После применения функции *softmax* мы получим вектор вероятностей  $[0.217, 0.536, 0.247]$  (сумма всех чисел равна 1).

Это означает, что модель считает, что изображение наиболее вероятно принадлежит классу собак.



1.5

0.217



2.3

0.536



0.8

0.247

# Метрики классификации



# Accuracy

**Просто количество угаданных примеров:**

$$\text{Accuracy} = \frac{1}{n} \sum_{i=1}^n [y_i^t = y_i^p]$$

# Accuracy

**Просто количество угаданных примеров:**

$$\text{Accuracy} = \frac{1}{n} \sum_{i=1}^n [y_i^t = y_i^p]$$

target: 1 0 1 0 0 0 0 1 0 0

predicted: 0 0 1 0 0 0 0 1 1 0

accuracy = 8/10 = 0.8

**Плохо при несбалансированных классах!**

# Матрица ошибок

Пусть :  
**positive** – класс “1”,  
**negative** – класс “-1”

|        |          | Predicted             |                       |
|--------|----------|-----------------------|-----------------------|
|        |          | Positive              | Negative              |
| Actual | Positive | <b>True positive</b>  | <b>False negative</b> |
|        | Negative | <b>False positive</b> | <b>True negative</b>  |

## Ещё метрики

- **Accuracy:**  $\frac{TP+TN}{TP+TN+FP+FN}$ .
- **Precision:**  $\frac{TP}{TP+FP}$ .
- **Recall:**  $\frac{TP}{TP+FN}$ .
- **F1:**  $2 * \frac{precision*recall}{precision+recall}$ .

**Тогда в новых  
обозначениях ...**

# Какую метрику выбрать?

Мы владеем компанией, предоставляющей услуги сотовой связи. Нам нужно, чтобы клиенты от нас не уходили к конкурентам.

Давайте попробуем предсказать, когда клиент захочет уйти, чтобы вовремя предложить им скидку (решаем **задачу оттока**).

Итак, цель — **выявлять клиентов в группе риска, чтобы компания вовремя предлагала им скидку.**

|              |   | Predicted class                                |                                                 |
|--------------|---|------------------------------------------------|-------------------------------------------------|
|              |   | +                                              | -                                               |
| Actual class | + | <b>TP</b><br>True Positives                    | <b>FN</b><br>False Negatives<br>(Type II error) |
|              | - | <b>FP</b><br>False Positives<br>(Type I error) | <b>TN</b><br>True Negatives                     |

# Какую метрику выбрать?

## Модель оттока:

- предсказывает вероятность ухода
- таргет:
  - 1 - клиент правда хочет уйти
  - 0 - клиент не собирается уходить

## Ошибка первого рода:

- модель: клиент собирается уходить, даём скидку
- клиент: я не собирался уходить:)

## Ошибка второго рода:

- модель: клиент не собирается уходить, не даём скидку
- клиент: я собрался уходить:(

|              |   | Predicted class                                |                                                 |
|--------------|---|------------------------------------------------|-------------------------------------------------|
|              |   | +                                              | -                                               |
| Actual class | + | <b>TP</b><br>True Positives                    | <b>FN</b><br>False Negatives<br>(Type II error) |
|              | - | <b>FP</b><br>False Positives<br>(Type I error) | <b>TN</b><br>True Negatives                     |

**Цель offline-оценки –  
подобрать гиперпараметры  
модели/инференса + выбрать  
модель.  
Обычно смотрят на ML-  
метрики.**

# Какую метрику выбрать?

**Потерять клиента == потерять выручку от него (LTV).**

$$TP(LTV - D_{cost}) + TN(LTV) + FP(LTV - D_{cost}) + FN(-LTV) \rightarrow \max$$

**LTV - Life Time Value** - суммарная выручка от клиента

ИЛИ

**“пожизненная ценность”** – предсказание чистого дохода, связанного со всеми будущими отношениями с клиентом.

|              |   | Predicted class                                |                                                 |
|--------------|---|------------------------------------------------|-------------------------------------------------|
|              |   | +                                              | -                                               |
| Actual class | + | <b>TP</b><br>True Positives                    | <b>FN</b><br>False Negatives<br>(Type II error) |
|              | - | <b>FP</b><br>False Positives<br>(Type I error) | <b>TN</b><br>True Negatives                     |

**Спасибо за внимание!**